

CONSTRUCCIÓN DE UN ÍNDICE DE VULNERABILIDAD FINANCIERA PARA PERSONAS NO BANCARIZADAS DEL PERÚ MEDIANTE MODELOS DE MIXTURAS GAUSSIANAS

CONSTRUCTION OF A FINANCIAL VULNERABILITY INDEX FOR UNBANKED PEOPLE IN PERU USING GAUSSIAN MIXTURE MODELS

Alumno: Michael Sebastian Flores Quispe

Docente: Demetrio Antonio Ruiz Olorte

Asignatura: Investigación Estadística

Escuela Profesional de Ingeniería Estadística

Facultad de Ingeniería Económica, Estadística y CCSS

Universidad Nacional de Ingeniería

RESUMEN

Este estudio construye un Índice de Vulnerabilidad Financiera (IVF) para personas no bancarizadas del Perú utilizando datos de la ENAHO 2024. La metodología combina Análisis de Correspondencias Múltiples, Modelos de Mixturas Gaussianas y el teorema de probabilidad total, incorporando FAC500A para obtener estimaciones poblacionales posteriores. Los resultados identifican cinco perfiles diferenciados, donde el Perfil 3 presenta la mayor vulnerabilidad, asociada a menor educación, menor acceso digital y presencia relevante de NBI. El IVF permite obtener una medida continua y comparable de vulnerabilidad financiera, con estabilidad evaluada mediante bootstrap simple. XGBoost y valores SHAP se emplean únicamente como herramientas auxiliares de interpretación, mostrando coherencia empírica con variables como NBI, acceso digital, educación, ingreso, informalidad y empleo vulnerable.

Palabras clave: *vulnerabilidad financiera, no bancarizados, GMM, SHAP, ENAHO.*

ABSTRACT

This study constructs a Financial Vulnerability Index (FVI) for unbanked individuals in Peru using ENAHO 2024 data. The methodology combines Multiple Correspondence Analysis, Gaussian Mixture Models, and the total probability theorem, incorporating FAC500A to obtain subsequent population-level estimates. The results identify five differentiated profiles, with Profile 3 showing the highest vulnerability, associated with lower education, lower digital access, and relevant presence of unmet basic needs. The FVI provides a continuous and comparable measure of financial vulnerability, with stability assessed through simple bootstrap. XGBoost and SHAP values are used only as auxiliary interpretation tools, showing empirical coherence with unmet basic needs, digital access, education, income, informality, and vulnerable employment.

Keywords: *financial vulnerability, unbanked population, GMM, SHAP, ENAHO.*

INTRODUCCIÓN

La inclusión financiera constituye una dimensión importante para la estabilidad económica de los hogares, pues permite acceder a mecanismos formales de ahorro, crédito, seguros y medios de pago. Sin embargo, una proporción significativa de la población peruana adulta permanece fuera del sistema financiero formal. Según la ENAHO del primer trimestre de 2024, el 60,0% de la población de 18 años a más contaba con alguna cuenta en el sistema financiero, cifra que alcanzaba el 64,8% en el área urbana y solo el 37,2% en el área rural (Instituto Nacional de Estadística e Informática [INEI], 2024). Esta brecha evidencia que la no bancarización continúa siendo un problema relevante, especialmente en contextos de informalidad laboral, bajos ingresos y desigualdad territorial.

La población no bancarizada enfrenta mayores restricciones para construir historial crediticio, acceder a financiamiento regulado y utilizar instrumentos seguros de ahorro. Además, no constituye un grupo homogéneo, pues dentro de ella coexisten trabajadores informales, hogares con carencias materiales, personas con bajo nivel educativo, población rural y ocupados en empleos vulnerables. La literatura reciente señala que la vulnerabilidad financiera es un fenómeno multidimensional asociado a ingresos, educación, empleo, condiciones de vida y capacidad para afrontar shocks económicos (He & Zhou, 2022; Fernández-López & Álvarez-Espino, 2024). Por ello, su medición requiere enfoques capaces de reconocer perfiles diferenciados en lugar de aplicar clasificaciones rígidas o indicadores aislados.

En este contexto, los Modelos de Mixturas Gaussianas (GMM) ofrecen una alternativa adecuada para identificar perfiles latentes de vulnerabilidad, debido a que asignan

probabilidades de pertenencia a cada grupo en lugar de clasificar a cada individuo de forma absoluta. Esta característica resulta útil cuando la vulnerabilidad financiera se entiende como una condición gradual y heterogénea. Estudios previos han mostrado la utilidad de la segmentación probabilística y de técnicas de clustering para representar perfiles financieros diferenciados en poblaciones heterogéneas (Arian et al., 2020; Hwang et al., 2022). Asimismo, criterios como el BIC y el ICL permiten seleccionar el número de perfiles considerando tanto el ajuste del modelo como la incertidumbre de clasificación (Biernacki et al., 2000; Scrucca et al., 2016).

La presente investigación construye un Índice de Vulnerabilidad Financiera (IVF) para personas no bancarizadas del Perú utilizando datos de la ENAHO 2024. Para ello, se combinan coordenadas obtenidas mediante Análisis de Correspondencias Múltiples para variables categóricas, variables socioeconómicas continuas estandarizadas y un GMM estimado sobre la base individual. El factor de expansión FAC500A se utiliza posteriormente para obtener estimaciones poblacionales, calcular los niveles promedio de vulnerabilidad por perfil y caracterizar los resultados. El índice final se define como una medida continua basada en las probabilidades posteriores de pertenencia a cada perfil y en el nivel promedio de vulnerabilidad asociado a dichos perfiles, siguiendo la lógica de los índices compuestos multidimensionales (Nardo et al., 2005).

Un aspecto central del enfoque propuesto es que las variables geográficas no se utilizan para formar los perfiles ni para calcular el IVF, sino que se reservan para la caracterización posterior y el análisis de heterogeneidad territorial. Finalmente, se emplean modelos XGBoost y valores SHAP únicamente con fines de interpretación y validación, identificando

las variables con mayor contribución explicativa sobre los perfiles obtenidos y el índice resultante. Los valores SHAP permiten mejorar la transparencia de modelos complejos al cuantificar la contribución de cada variable a las predicciones, sin intervenir en la construcción del índice (Lundberg & Lee, 2017; Bussmann et al., 2020).

FORMULACIÓN DEL PROBLEMA DE INVESTIGACIÓN

¿Cómo construir un Índice de Vulnerabilidad Financiera para personas no bancarizadas del Perú, utilizando información socioeconómica de la ENAHO 2024, que permita identificar perfiles latentes diferenciados de vulnerabilidad mediante Modelos de Mixturas Gaussianas e incorporar probabilísticamente la pertenencia de cada individuo a dichos perfiles?

IMPORTANCIA Y JUSTIFICACIÓN

La presente investigación es importante porque busca medir la vulnerabilidad financiera de la población no bancarizada del Perú, un grupo que enfrenta restricciones para acceder a cuentas, crédito formal, seguros y mecanismos seguros de ahorro. Esta población presenta una alta heterogeneidad en ingresos, educación, informalidad laboral, condiciones de vida y acceso digital, por lo que no resulta adecuado analizarla como un conjunto homogéneo. La literatura reciente señala que la vulnerabilidad financiera es un fenómeno multidimensional asociado a factores económicos, laborales y sociales (He & Zhou, 2022; Fernández-López & Álvarez-Espino, 2024).

Desde el punto de vista aplicado, el Índice de Vulnerabilidad Financiera propuesto permite obtener una medida continua y comparable entre individuos, útil para ordenar niveles de riesgo y priorizar

intervenciones. A diferencia de una clasificación binaria, el índice incorpora probabilidades posteriores de pertenencia a perfiles latentes, lo que permite representar mejor la heterogeneidad y los casos intermedios dentro de la población no bancarizada. Este enfoque resulta pertinente en contextos donde la falta de historial financiero formal limita el uso de modelos tradicionales de evaluación crediticia (Arian et al., 2020; Hwang et al., 2022).

Metodológicamente, la investigación se justifica porque combina Análisis de Correspondencias Múltiples, Modelos de Mixturas Gaussianas e interpretabilidad mediante XGBoost y valores SHAP. El uso de GMM permite identificar perfiles latentes mediante asignación probabilística, mientras que el IVF se construye siguiendo la lógica de los índices compuestos multidimensionales, que recomiendan una selección justificada de variables, normalización y agregación transparente de indicadores (McLachlan & Peel, 2000; Nardo et al., 2005). Finalmente, los valores SHAP se utilizan únicamente para interpretar y validar los perfiles obtenidos, sin intervenir en la construcción del índice (Lundberg & Lee, 2017).

OBJETIVOS

OBJETIVO GENERAL.

Construir un Índice de Vulnerabilidad Financiera para personas no bancarizadas del Perú, utilizando datos de la ENAHO 2024, a partir de perfiles latentes estimados mediante Modelos de Mixturas Gaussianas y probabilidades posteriores de pertenencia.

OBJETIVOS ESPECÍFICOS.

1. Preparar la base analítica de personas no bancarizadas de 18 a 65 años a

partir de la ENAHO 2024, construyendo variables socioeconómicas, laborales, educativas, digitales y de condiciones de vida relevantes para la medición de vulnerabilidad financiera.

2. Identificar perfiles latentes de vulnerabilidad financiera mediante Modelos de Mixturas Gaussianas, seleccionando el número de perfiles con criterios de ajuste, clasificación e interpretabilidad.
3. Construir el IVF como una medida continua y probabilística, combinando las probabilidades posteriores de pertenencia a cada perfil con el nivel promedio de vulnerabilidad estimado para cada grupo.
4. Evaluar la coherencia empírica y estabilidad del IVF mediante caracterización socioeconómica, comparación urbano-rural, bootstrap e interpretación auxiliar con XGBoost y SHAP.

MARCO TEÓRICO

ANTECEDENTES DE LA INVESTIGACIÓN

Diversas investigaciones han utilizado técnicas de segmentación y aprendizaje automático para analizar fenómenos financieros caracterizados por alta heterogeneidad entre individuos u hogares. Arian et al. (2020) emplearon Modelos de Mixturas Gaussianas para estimar probabilidades de incumplimiento crediticio, mostrando que la asignación probabilística permite representar de manera más flexible la diversidad de perfiles de riesgo. De forma complementaria, Hwang et al. (2022) aplicaron técnicas de clustering para identificar patrones diferenciados de comportamiento financiero en hogares,

evidenciando que la segmentación constituye una herramienta útil para caracterizar grupos con distintos niveles de exposición financiera.

Por otra parte, la literatura sobre vulnerabilidad financiera destaca que este fenómeno posee una naturaleza multidimensional. He y Zhou (2022) señalan que la vulnerabilidad de los hogares se relaciona con la exposición a shocks de ingreso y gasto, así como con factores socioeconómicos que condicionan la capacidad de respuesta ante eventos adversos. En la misma línea, Fernández-López y Álvarez-Espiño (2024) sostienen que el análisis de hogares vulnerables requiere considerar dimensiones como ingresos, educación, empleo, condiciones de vida y acceso a recursos financieros, debido a que una sola variable no permite capturar adecuadamente la complejidad del fenómeno.

Asimismo, la construcción de indicadores compuestos ha sido ampliamente utilizada para sintetizar fenómenos sociales y económicos multidimensionales. Nardo et al. (2005) proponen lineamientos metodológicos para la construcción de índices compuestos, destacando la importancia de contar con un marco conceptual claro, seleccionar variables justificadas, normalizar indicadores, definir reglas transparentes de agregación y evaluar la robustez de los resultados. Estos criterios resultan relevantes para la construcción de un Índice de Vulnerabilidad Financiera, en la medida en que este busca integrar múltiples dimensiones socioeconómicas en una medida continua y comparable.

En relación con la interpretabilidad de modelos, Lundberg y Lee (2017) introducen el enfoque SHAP como una metodología basada en valores de Shapley para explicar predicciones individuales y globales de modelos complejos. En aplicaciones financieras, Bussmann et al.

(2020) muestran que SHAP puede mejorar la transparencia de modelos de riesgo crediticio, mientras que Chen et al. (2025) emplean esta herramienta para analizar factores asociados a la vulnerabilidad financiera de los hogares. Estos antecedentes respaldan el uso de SHAP como herramienta de interpretación posterior, especialmente cuando se emplean modelos supervisados auxiliares para explicar perfiles o índices construidos previamente.

En conjunto, la evidencia revisada muestra que la segmentación probabilística, la medición multidimensional de la vulnerabilidad financiera y la interpretabilidad mediante aprendizaje automático han sido abordadas principalmente de manera separada. En ese sentido, la presente investigación busca integrar estos enfoques mediante la construcción de un Índice de Vulnerabilidad Financiera para personas no bancarizadas del Perú, combinando perfiles latentes estimados con Modelos de Mixturas Gaussianas, probabilidades posteriores de pertenencia, niveles promedio de vulnerabilidad por perfil e interpretación posterior mediante XGBoost y valores SHAP.

BASES TEÓRICAS

Índices compuestos y medición multidimensional

Los índices compuestos son herramientas metodológicas utilizadas para sintetizar fenómenos complejos que no pueden ser representados adecuadamente mediante una sola variable. Su finalidad es integrar múltiples indicadores en una medida agregada, permitiendo comparar unidades de análisis, ordenar niveles relativos de un fenómeno y facilitar la interpretación de información multidimensional.

Este tipo de índices se emplea ampliamente en campos como pobreza, desarrollo humano, sostenibilidad,

bienestar social e inclusión financiera, debido a que muchos fenómenos económicos y sociales presentan una naturaleza multidimensional. En estos casos, cada indicador individual captura solo una parte del fenómeno, por lo que su combinación permite obtener una representación más amplia y sistemática.

De acuerdo con Nardo et al. (2005), la construcción de un índice compuesto requiere seguir un conjunto de etapas metodológicas que permitan garantizar coherencia conceptual, transparencia en la agregación y robustez de los resultados. Estos lineamientos se resumen en la siguiente tabla:

Paso	Lineamiento	Descripción
1	Marco teórico	Definir el fenómeno que se desea medir, sus dimensiones principales y la relación esperada entre ellas.
2	Selección de variables	Elegir indicadores relevantes, disponibles y justificados teóricamente.
3	Tratamiento de datos faltantes	Identificar valores perdidos y aplicar procedimientos adecuados de corrección o imputación.
4	Análisis multivariante	Evaluar la estructura de relaciones entre variables, redundancias y patrones subyacentes.
5	Normalización	Transformar los indicadores a una escala común para hacerlos comparables.
6	Ponderación y agregación	Definir cómo se asigna importancia a cada indicador y cómo se combinan en una medida sintética.
7	Robustez y sensibilidad	Evaluar la estabilidad del índice ante cambios en supuestos, variables o métodos de agregación.
8	Descomposición del índice	Analizar la contribución de cada dimensión o indicador al resultado

		final.
9	Relación con variables externas	Comparar el índice con variables relacionadas para evaluar su coherencia empírica.
10	Presentación y visualización	Comunicar los resultados de manera clara mediante tablas, gráficos u otras herramientas interpretativas.

La normalización es una etapa fundamental, ya que permite transformar indicadores medidos en distintas escalas a una métrica común. Posteriormente, la ponderación y agregación determinan cómo se combinan las dimensiones consideradas dentro del índice. Estas decisiones metodológicas deben ser transparentes, debido a que pueden influir directamente en el resultado final y en la interpretación del fenómeno analizado.

Asimismo, los índices compuestos requieren análisis de sensibilidad y robustez para evaluar si los resultados se mantienen estables frente a cambios en los supuestos de construcción, selección de variables, métodos de normalización o criterios de ponderación. Por ello, su utilidad no depende únicamente de resumir información, sino también de la coherencia conceptual y metodológica con la que son contruidos.

Índice compuesto probabilístico y teorema de probabilidad total

Un índice compuesto probabilístico permite representar fenómenos en los que las unidades de análisis no pertenecen de manera rígida a un único grupo, sino que presentan probabilidades de pertenencia a distintos perfiles o componentes latentes. Este enfoque se relaciona con el teorema de probabilidad total, pues el valor del índice se obtiene como una suma ponderada de los niveles de referencia de cada componente.

Sea $i=1, \dots, n$ una unidad de análisis y $k=1, \dots, K$ un conjunto de componentes latentes. Si cada componente posee un nivel de referencia R_k y cada unidad tiene una probabilidad de pertenencia τ_{ik} , el índice puede definirse como:

$$I_i = \sum_{k=1}^K \tau_{ik} R_k$$

Donde I_i es el valor del índice para la unidad i , τ_{ik} es la probabilidad de pertenencia al componente k , y R_k es el nivel de referencia de dicho componente. Para conservar su interpretación probabilística, se requiere que:

$$0 \leq \tau_{ik} \leq 1$$

$$\sum_{k=1}^K \tau_{ik} = 1$$

Cuando existen pesos muestrales o poblacionales, el nivel de referencia de cada componente puede calcularse como un promedio ponderado de un indicador auxiliar V_i :

$$R_k = \frac{\sum_{i \in C_k} w_i V_i}{\sum_{i \in C_k} w_i}$$

Donde C_k representa el conjunto de unidades asignadas al componente k , w_i es el peso de la unidad i , y V_i es un indicador previamente normalizado del fenómeno analizado.

Esta formulación permite combinar la medición multidimensional de un fenómeno con la incertidumbre asociada a la pertenencia a perfiles latentes, evitando clasificaciones rígidas o binarias.

Análisis de Correspondencias Múltiples (MCA)

El Análisis de Correspondencias Múltiples (MCA) es una técnica de reducción

dimensional diseñada para el tratamiento de variables categóricas. Su objetivo principal consiste en representar las relaciones existentes entre múltiples categorías dentro de un espacio factorial de menor dimensión, preservando la mayor cantidad posible de la inercia (información) contenida en los datos (Greenacre, 2007).

A diferencia del Análisis de Componentes Principales (PCA), que se utiliza con variables continuas, el MCA permite trabajar con variables nominales y ordinales, transformándolas en coordenadas continuas que pueden emplearse posteriormente en procedimientos estadísticos de clasificación. Debido a que gran parte de las variables socioeconómicas provenientes de encuestas de hogares presentan una naturaleza categórica, el MCA constituye la alternativa idónea para generar representaciones continuas sin perder la estructura de asociación entre categorías.

Formalmente, el MCA analiza una matriz indicadora disyuntiva completa Z o, de manera equivalente, la Matriz de Burt (B), definida como:

$$B = Z^T Z$$

Para medir la asociación entre las categorías de las variables, se utiliza la distancia de Chi-cuadrado (χ^2) entre los perfiles de dos observaciones i y i' , expresada matemáticamente como:

$$d^2(i, i') = \sum_{j=1}^J \frac{1}{p_{\cdot j}} \left(\frac{p_{ij}}{p_{i\cdot}} - \frac{p_{i'j}}{p_{i'\cdot}} \right)^2$$

Donde J representa el número total de categorías, p_{ij} es la frecuencia relativa observada, y $p_{i\cdot}$ junto a $p_{\cdot j}$ corresponden a las masas marginales de las filas y columnas, respectivamente. A través de la descomposición en valores propios de esta

estructura, el MCA proyecta las observaciones en un espacio factorial continuo de menor dimensión, preservando la inercia de los datos categóricos.

Modelos de Mezcla Gaussiana (GMM)

Los Modelos de Mixtura Gaussiana (Gaussian Mixture Models, GMM) pertenecen a la familia de métodos de aprendizaje no supervisado probabilísticos utilizados para identificar grupos latentes dentro de una población heterogénea. A diferencia de los métodos de clustering tradicionales (hard clustering), los GMM asumen que los datos son generados por una combinación de múltiples distribuciones gaussianas, permitiendo que cada observación posea una probabilidad continua de pertenencia a cada grupo identificado (McLachlan & Peel, 2000).

Conceptualmente, un GMM modela la distribución conjunta de los datos como una combinación ponderada de componentes gaussianos:

$$p(x) = \sum_{k=1}^K \pi_k N(x|\mu_k, \Sigma_k)$$

donde K representa el número de componentes, π_k la proporción de mezcla asociada a cada grupo y $N(x|\mu_k, \Sigma_k)$ la distribución normal multivariada correspondiente con su respectiva media μ_k y matriz de covarianzas Σ_k .

La estimación de los parámetros del modelo se realiza usualmente mediante el algoritmo de Esperanza-Maximización (EM), calculando la probabilidad a posteriori o responsabilidad (γ_{ik}). Esta representa la probabilidad de que una observación i pertenezca a un componente latente k dada su información observada x_i :

$$\gamma_{ik} = P(C_k|x_i) = \frac{\pi_k N(x_i|\mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j N(x_i|\mu_j, \Sigma_j)}$$

Selección del número de componentes:

BIC, ICL y entropía

En los Modelos de Mixturas Gaussianas, la elección del número de componentes K es una decisión fundamental, ya que determina la cantidad de perfiles latentes que se utilizarán para representar la heterogeneidad de los datos. Un número reducido de componentes puede simplificar excesivamente la estructura poblacional, mientras que un número demasiado alto puede generar sobreajuste y perfiles poco interpretables.

Uno de los criterios más utilizados para seleccionar K es el Criterio de Información Bayesiano, conocido como BIC. Este criterio compara modelos con distinto número de parámetros, penalizando aquellos que incrementan innecesariamente la complejidad. Su expresión general es:

$$BIC = -2 \ln(\hat{L}) + d \ln(n)$$

Donde $\hat{L}$ es el máximo de la función de verosimilitud, d es el número de parámetros estimados y n es el tamaño de la muestra.

Sin embargo, en problemas de clasificación latente, un buen ajuste global no garantiza necesariamente una separación clara entre componentes. Por ello, Biernacki et al. (2000) proponen el Criterio de Información de Clasificación, o ICL, que incorpora una penalización adicional asociada a la incertidumbre de clasificación. De manera general, puede expresarse como:

$$ICL = BIC + 2 \times EN(\hat{C})$$

Donde $EN(\hat{C})$ representa la entropía de las probabilidades a posteriori (responsabilidades γ_{ik}), calculada como:

$$EN(\hat{C}) = - \sum_{i=1}^n \sum_{k=1}^K \hat{\gamma}_{ik} \ln(\hat{\gamma}_{ik})$$

La entropía cuantifica la incertidumbre en la asignación de las observaciones a los perfiles; valores de entropía cercanos a cero indican que los componentes están claramente separados y que cada individuo tiene una pertenencia dominante a un único grupo.

Pesos de expansión

En encuestas complejas, las observaciones pueden representar a un número distinto de unidades de la población. Por ello, se emplean factores de expansión, como FAC500A en la ENAHO, para calcular estimaciones poblacionales de totales, proporciones, medias y otros indicadores. En este estudio, FAC500A no se incorporó como variable de entrada ni como peso de entrenamiento del GMM. El modelo de mezclas se estimó directamente sobre la matriz individual procesada X_{gmm} . El factor de expansión se utilizó posteriormente para calcular tamaños poblacionales, promedios ponderados por perfil, niveles de vulnerabilidad R_k , medias territoriales y resúmenes poblacionales.

La media ponderada de una variable X_i se interpreta como la suma de los valores individuales multiplicados por sus pesos, dividida entre la suma total de pesos. Esta lógica se aplicó para caracterizar perfiles y para estimar R_k , pero no para formar directamente los perfiles latentes. Esta distinción evita confundir representatividad poblacional con pertenencia latente: FAC500A corrige la lectura poblacional de los resultados, mientras que el GMM identifica patrones de segmentación a partir de las variables analíticas procesadas.

XGBoost e interpretabilidad de modelos
XGBoost (Extreme Gradient Boosting) es un algoritmo de aprendizaje supervisado basado en un ensamble de árboles de decisión construidos secuencialmente mediante técnicas de optimización de gradiente (gradient boosting). Su popularidad se debe a su elevada capacidad predictiva, eficiencia computacional y flexibilidad para trabajar con datos estructurados de diversa naturaleza (Chen & Guestrin, 2016).

No obstante, al igual que otros modelos avanzados de aprendizaje automático, XGBoost suele ser considerado de tipo "caja negra" debido a la dificultad para interpretar directamente la contribución matemática no lineal de cada variable en las predicciones generadas.

Valores SHAP para interpretación de modelos

Los valores SHAP (SHapley Additive exPlanations) constituyen una metodología de interpretabilidad basada en la teoría de juegos cooperativos propuesta originalmente por Shapley (1988).

El valor Shapley (ϕ_j) de una variable j para una predicción específica x se define como su contribución marginal promedio a través de todas las posibles coaliciones de variables:

$$\phi_j(x) = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|! (|F| - |S| - 1)!}{|F|!} [f_x(S \cup \{j\}) - f_x(S)]$$

Esta formulación asegura que la suma de las contribuciones de todas las variables equivalga a la diferencia entre la predicción actual y el valor esperado promedio del modelo, garantizando la propiedad de aditividad local en la interpretabilidad de algoritmos de caja negra.

El principio fundamental consiste en asignar a cada variable una contribución marginal al resultado generado por un modelo, considerando todas las posibles combinaciones (coaliciones) entre variables (Lundberg & Lee, 2017).

En el contexto del aprendizaje automático, SHAP permite cuantificar la influencia de cada característica sobre las predicciones individuales (locales) y globales del modelo. Esta propiedad facilita la identificación de los factores más relevantes asociados a un fenómeno de interés, manteniendo consistencia teórica y capacidad explicativa. Diversas investigaciones recientes han aplicado SHAP en ámbitos relacionados con el riesgo crediticio, la estabilidad financiera y el comportamiento financiero, demostrando su utilidad para interpretar modelos complejos (Bussmann et al., 2020; Tan et al., 2023).

Precisión metodológica: En la presente investigación, los valores SHAP se utilizan exclusivamente para interpretar el modelo XGBoost empleado en la validación de la segmentación obtenida mediante GMM. Los valores SHAP no se emplean para ponderar ni construir el Índice de Vulnerabilidad Financiera (IVF). La construcción del índice se realiza mediante la combinación de probabilidades de pertenencia a perfiles e indicadores socioeconómicos normalizados utilizando el teorema de probabilidad total, siguiendo los lineamientos de la OCDE para índices compuestos.

MARCO CONCEPTUAL

Vulnerabilidad Financiera

La vulnerabilidad financiera se refiere a una condición de fragilidad económica que limita la capacidad de una persona u hogar para enfrentar shocks adversos, como caídas de ingresos, gastos imprevistos, enfermedad, desempleo o restricciones de

liquidez. A diferencia de la pobreza monetaria, que describe una situación observada en un momento determinado, la vulnerabilidad financiera incorpora una dimensión de exposición al riesgo y capacidad de respuesta ante eventos futuros.

Este concepto se relaciona con la estabilidad de los ingresos, la disponibilidad de activos o ahorros, la calidad del empleo, el acceso a mecanismos de protección financiera y las condiciones materiales de vida. Por ello, una persona puede no encontrarse en situación de pobreza monetaria, pero sí presentar vulnerabilidad financiera si carece de recursos suficientes para afrontar contingencias económicas. La literatura reciente sostiene que este fenómeno debe analizarse desde una perspectiva multidimensional, debido a que depende simultáneamente de factores económicos, laborales, educativos y sociales (He & Zhou, 2022; Fernández-López & Álvarez-Espino, 2024).

Población no bancarizada y multidimensionalidad

La población no bancarizada está conformada por personas que no acceden o no utilizan productos financieros formales, como cuentas de ahorro, crédito regulado, seguros o medios de pago ofrecidos por instituciones del sistema financiero. Esta situación restringe la posibilidad de construir historial financiero, acceder a instrumentos seguros de ahorro y contar con mecanismos formales para enfrentar emergencias económicas.

La no bancarización no debe entenderse únicamente como ausencia de una cuenta financiera, sino como una condición asociada a múltiples barreras económicas, sociales e institucionales. Entre ellas se encuentran la insuficiencia de ingresos, la informalidad laboral, el bajo nivel educativo, las limitaciones de acceso

digital, la desconfianza en el sistema financiero y las brechas territoriales. En este sentido, la población no bancarizada constituye un grupo heterogéneo, compuesto por personas con distintos niveles de exposición a riesgos financieros y diferentes capacidades para responder ante ellos.

La multidimensionalidad resulta clave para analizar este fenómeno, ya que ninguna variable por sí sola permite capturar completamente la vulnerabilidad financiera. Los ingresos aproximan la capacidad económica disponible; la educación puede influir en el acceso y uso de servicios financieros; la informalidad laboral refleja inestabilidad y ausencia de protección social; las condiciones de vida expresan carencias estructurales; y el acceso digital puede facilitar o limitar la incorporación a servicios financieros modernos.

Perfiles latentes e índice de vulnerabilidad financiera

Los perfiles latentes son grupos no observados directamente, inferidos a partir de patrones comunes en un conjunto de variables. A diferencia de categorías previamente definidas, los perfiles latentes se construyen estadísticamente y permiten representar la heterogeneidad interna de una población. En contextos sociales y financieros, estos perfiles pueden reflejar combinaciones diferenciadas de condiciones económicas, laborales, educativas y de acceso a recursos.

El uso de perfiles latentes permite superar clasificaciones rígidas o binarias, debido a que reconoce que las unidades de análisis pueden compartir características con más de un grupo. Esta idea es especialmente relevante cuando el fenómeno estudiado no se presenta de manera absoluta, sino gradual. Así, una persona puede presentar características asociadas a distintos niveles de vulnerabilidad, lo que requiere una

medición más flexible que una simple asignación a una categoría única.

Un índice de vulnerabilidad financiera puede entenderse como una medida sintética y continua que resume diferentes dimensiones asociadas a la fragilidad económica. Su finalidad es ordenar a las unidades de análisis según su nivel relativo de vulnerabilidad, facilitando la comparación entre individuos o grupos. Cuando este índice incorpora perfiles latentes y probabilidades de pertenencia, permite representar tanto la multidimensionalidad del fenómeno como la incertidumbre existente en la clasificación de las personas dentro de distintos niveles de riesgo.

METODOLOGÍA

La presente investigación corresponde a un estudio de nivel explicativo, en la medida en que no se limita a describir la vulnerabilidad financiera de la población no bancarizada del Perú, sino que busca identificar perfiles latentes y analizar los factores socioeconómicos asociados a dichos perfiles. El diseño es no experimental, debido a que las variables se observan en su estado natural, sin manipulación deliberada, y de corte transversal, pues la información corresponde al año 2024.

Los datos provienen de la Encuesta Nacional de Hogares (ENAH) 2024, elaborada por el Instituto Nacional de Estadística e Informática (INEI). El universo de estudio está conformado por personas de 18 a 65 años clasificadas como no bancarizadas, de acuerdo con la variable de inclusión financiera utilizada para identificar a quienes no cuentan con una cuenta en el sistema financiero formal. Debido al diseño muestral de la encuesta, se incorporó el factor de expansión FAC500A para aproximar estimaciones representativas de la población.

El tratamiento de los datos se desarrolló en varias etapas. Primero, se construyó una base individual a partir de los módulos relevantes de la ENAH 2024, conservando información sociodemográfica, educativa, laboral, económica, financiera, geográfica y de condiciones de vida. Posteriormente, se identificaron y trataron valores perdidos o códigos no válidos, se recodificaron variables categóricas y se construyeron indicadores derivados relacionados con informalidad laboral, empleo vulnerable, ingreso, necesidades básicas insatisfechas y acceso digital. La dificultad de pago de crédito fue evaluada inicialmente, pero se excluyó del score auxiliar final debido a su baja variabilidad efectiva. Las variables con mayor proporción de valores faltantes, incluido el ingreso total mensual, fueron imputadas mediante MICE; en el caso del ingreso, la imputación se realizó sobre el log-ingreso y luego se recuperó su escala original para el análisis. Las variables con menor proporción de faltantes fueron imputadas mediante mediana o moda, según su naturaleza.

Variables consideradas en el análisis

Dimensión	Variables	Descripción	Uso principal
Población objetivo	P558E1_6	No tenencia de cuenta formal	Filtro de no bancarización
Sociodemográfica	P207, P208A, P209, P558C	Sexo, edad, estado civil y etnia	MCA/GMM, perfilado y XGBoost
Educativa	P301A; P302	Educación y alfabetismo	P301A en GMM y Vi; P302 excluida por faltantes
Laboral	P507, P511A, P512A	Ocupación, contrato y empresa	P507 en MCA; informalidad/empleo vulnerable en Vi y perfilado
Económica	P524A1, P530A	Ingreso laboral total	GMM, Vi, perfilado y XGBoost
Condiciones de vida	NBI1-NBI5	Necesidades básicas insatisfechas	GMM, Vi, perfilado y XGBoost
Acceso digital	P1142, P1144, P1145	Computadora, internet y uso personal	GMM, Vi, perfilado y XGBoost
Financiera y crédito	P558F, P558G, P107B	Barreras y mecanismos informales; dificultad evaluada	MCA y perfilado; P107B excluida de Vi
Geográfica	DOMINIO, ESTRATO, UBIGEO	Área, dominio, estrato y ubicación	Caracterización; aux. en MICE ingreso
Ponderación	FAC500A	Factor de	Medias, Rk y

Dimensión	Variables	Descripción	Uso principal
		expansión	población expandida

Las variables empleadas se organizaron según su función dentro del análisis. Las variables categóricas, como sexo, estado civil, categoría ocupacional, razones de no tenencia de cuenta o crédito y uso de mecanismos financieros informales, fueron transformadas mediante Análisis de Correspondencias Múltiples (MCA), con el fin de obtener coordenadas continuas que sintetizan la estructura de asociación entre categorías. Estas coordenadas se integraron con cinco variables continuas u ordinales estandarizadas: edad, nivel educativo ordinal, ingreso total, NBI y acceso digital. Informalidad y empleo vulnerable no ingresaron directamente a Xgmm, porque son redundantes con la categoría ocupacional; se utilizaron en el score auxiliar V_i , en la caracterización y en los modelos auxiliares.

La segmentación de la población se realizó mediante Modelos de Mixturas Gaussianas (GMM), estimando distintos números de componentes sobre la base individual procesada. El número óptimo de perfiles se seleccionó a partir del Criterio de Información Bayesiano (BIC), el Criterio de Información de Clasificación (ICL) y la entropía de clasificación. El factor de expansión FAC500A no se utilizó como variable de entrada del GMM, sino posteriormente para calcular estimaciones poblacionales, tamaños expandidos, promedios ponderados por perfil y niveles promedio de vulnerabilidad.

Para construir el Índice de Vulnerabilidad Financiera (IVF), primero se definió un indicador auxiliar de vulnerabilidad V_i , calculado a partir de dimensiones normalizadas asociadas a ingreso, educación, informalidad laboral, necesidades básicas insatisfechas, empleo vulnerable y acceso digital. La variable dificultad de pago fue evaluada en el

procesamiento inicial, pero no se incorporó al score auxiliar final debido a su baja variabilidad efectiva en la base analítica. Las dimensiones del score auxiliar V_i se agregaron con ponderaciones iguales. Esta decisión responde a un criterio de transparencia metodológica y evita imponer pesos arbitrarios sin una fuente externa que justifique una mayor importancia relativa de una dimensión sobre otra. Además, al tratarse de un indicador auxiliar utilizado para ordenar los niveles promedio de vulnerabilidad por perfil, la ponderación igual permite mantener una interpretación directa y replicable del procedimiento.

A partir de este indicador, se estimó para cada perfil un nivel promedio de vulnerabilidad (R_k), utilizando promedios ponderados por FAC500A. Luego, el IVF individual se obtuvo como una combinación ponderada de las probabilidades posteriores de pertenencia estimadas por el GMM y los niveles de vulnerabilidad de cada perfil, siguiendo el enfoque de índice compuesto probabilístico basado en el teorema de probabilidad total.

Las variables geográficas, como área de residencia, dominio territorial o tamaño poblacional, no fueron utilizadas directamente para formar los perfiles ni para calcular el índice. Se reservaron para la caracterización posterior y el análisis de heterogeneidad territorial. En el tratamiento del ingreso, dominio y estrato sí se utilizaron como predictores auxiliares dentro de la imputación, pero no como componentes directos del GMM ni del IVF.

Finalmente, se entrenaron modelos XGBoost como herramientas auxiliares para reproducir la asignación de perfiles obtenida mediante GMM y para analizar el comportamiento del índice resultante. Los valores SHAP se utilizaron exclusivamente con fines interpretativos, identificando las

variables con mayor contribución predictiva en los modelos auxiliares. Por tanto, XGBoost y SHAP no intervienen en la ponderación ni en la construcción del IVF, ni deben interpretarse como evidencia causal, sino como una evaluación complementaria de coherencia e interpretabilidad empírica. Todo el procesamiento se realizó en Python mediante Google Colab, utilizando principalmente las librerías pandas, numpy, scikit-learn, prince, xgboost y shap.

RESULTADOS

Selección del número de perfiles

Se estimaron modelos GMM con distintos números de perfiles. Según los criterios BIC, ICL y entropía, la mejor solución fue trabajar con cinco perfiles latentes. Esta cantidad permite representar adecuadamente la heterogeneidad de la población no bancarizada sin generar grupos excesivamente fragmentados.

La siguiente tabla muestra que el modelo con cinco perfiles presenta el mejor ajuste y mantiene una clasificación suficientemente clara. Por ello, se seleccionó $K=5$ como número final de perfiles para construir el índice.

K	BIC	ICL	Entropía	$E/\ln(K)$
2	10,526.1	10,602.0	0.0013	0.0018
3	-295,630.9	-295,501.6	0.0022	0.0020
4	-500,435.8	-500,341.3	0.0016	0.0011
5	-604,821.4	-604,423.0	0.0066	0.0041

Tabla 1: Criterios de selección del número de perfiles

Construcción y distribución del IVF

Después de seleccionar los cinco perfiles, se calculó para cada grupo un nivel promedio de vulnerabilidad. Estos valores permiten ordenar los perfiles desde menor hasta mayor vulnerabilidad financiera.

La tabla de distribución de perfiles muestra tres aspectos principales: el tamaño de cada grupo en la muestra, su representación poblacional usando FAC500A y su nivel promedio de vulnerabilidad. A partir de estos valores se construyó el IVF individual, combinando la pertenencia probabilística de cada persona a los perfiles estimados.

Perfil	R_k	N muestra	N población
Perfil 1	0.5188	12,810	3,767,383
Perfil 2	0.3133	5,451	2,096,007
Perfil 3	0.5951	2,218	519,269
Perfil 4	0.4357	4,178	1,364,805
Perfil 5	0.5151	5,297	1,496,131

Tabla 2: Distribución de perfiles y su vulnerabilidad promedio

La distribución del IVF muestra que la vulnerabilidad financiera no se divide simplemente entre personas vulnerables y no vulnerables. Por el contrario, el índice permite observar distintos niveles de vulnerabilidad dentro de la población no bancarizada. Esto confirma que el IVF funciona como una medida continua y comparable entre individuos.




Figura 1: Distribución del IVF.

Caracterización socioeconómica de los perfiles

La caracterización socioeconómica permite interpretar qué representa cada perfil. Para ello, se compararon variables como ingreso, edad, NBI, informalidad,

empleo vulnerable, educación y acceso digital.

La tabla muestra que el perfil con mayor vulnerabilidad es el Perfil 3, mientras que el de menor vulnerabilidad es el Perfil 2. El orden general de vulnerabilidad es: Perfil 3, Perfil 1, Perfil 5, Perfil 4 y Perfil 2.

Variable	Perfil 1	Perfil 2	Perfil 3	Perfil 4	Perfil 5
IVF medio	0.5185	0.3133	0.5951	0.4359	0.5150
Ingreso medio (\$/)	624.0	1037.5	569.8	1089.9	585.4
Edad media	44.1	31.1	43.4	40.5	38.8
NBI medio	0.000	0.000	0.419	0.353	0.922
Informalidad	82.9 %	39.4 %	77.0 %	68.4 %	77.9 %
Empleo vulnerable	72.4 %	0.0 %	54.2 %	35.3 %	50.1 %
Educación ordinal media	4.09	4.62	3.40	4.56	3.91
Acceso digital medio	2.00	2.00	0.953	2.00	2.00
Mujeres	56.2 %	46.8 %	44.7 %	51.5 %	43.9 %

Tabla 3: Caracterización socioeconómica de los perfiles

El Perfil 1 puede interpretarse como un *perfil de vulnerabilidad laboral alta*, debido a que combina elevada informalidad y alta presencia de empleo vulnerable. Aunque no presenta un nivel promedio relevante de NBI, su vulnerabilidad proviene principalmente de la fragilidad de su inserción laboral.

El Perfil 2 se interpreta como el grupo de *menor vulnerabilidad relativa* dentro de la población no bancarizada. Presenta mejores condiciones de ingreso y educación, menor informalidad y ausencia de empleo vulnerable. Sin embargo, su menor vulnerabilidad debe entenderse de forma relativa, ya que todos los individuos del análisis pertenecen a la población no bancarizada.

El Perfil 3 puede denominarse *vulnerabilidad estructural alta*, pues presenta el mayor nivel de vulnerabilidad financiera. Su situación se asocia con menor nivel educativo, menor acceso digital y presencia relevante de necesidades básicas insatisfechas, lo que refleja restricciones más estructurales que afectan la capacidad de respuesta financiera.

El Perfil 4 se interpreta como un *perfil de vulnerabilidad intermedia* con ingresos relativos altos. Aunque registra ingresos promedio superiores a varios perfiles, mantiene presencia de informalidad y NBI. Esto evidencia que un mayor ingreso promedio no elimina necesariamente otras fuentes de vulnerabilidad financiera.

El Perfil 5 puede caracterizarse como un *perfil de vulnerabilidad material e informalidad alta*, debido a la elevada presencia de necesidades básicas insatisfechas y altos niveles de informalidad. Este grupo combina carencias materiales con fragilidad laboral, ubicándose en un nivel de vulnerabilidad alta-media.

En conjunto, estos resultados muestran que la población no bancarizada no es homogénea. Existen perfiles cuya vulnerabilidad se explica principalmente por empleo informal, otros por carencias materiales y otros por menor educación o acceso digital.

Caracterización territorial: urbano-rural

La gráfica urbano-rural muestra que los perfiles con mayor vulnerabilidad presentan una mayor presencia relativa en el área rural. En particular, el Perfil 3, denominado “vulnerabilidad estructural alta”, y el Perfil 5, denominado “vulnerabilidad material e informalidad alta”, concentran una mayor proporción rural en comparación con los perfiles de menor vulnerabilidad.

Este resultado sugiere que la ruralidad está asociada con una mayor concentración de condiciones vulnerables, especialmente aquellas vinculadas a menor acceso digital, presencia de NBI, informalidad y carencias materiales. No obstante, la ruralidad no define directamente el IVF, ya que las variables geográficas no fueron incluidas en el GMM ni en el cálculo del índice.




Figura 2: Composición urbano-rural por perfil.

Interpretación auxiliar con XGBoost y SHAP

Para complementar la interpretación del índice, se entrenó un modelo XGBoost usando el IVF como variable objetivo. Este modelo no construye el índice, sino que sirve para observar qué variables ayudan a explicarlo.

Metrica	Valor
RMSE	0.0375
R^2	0.7996

Tabla 4: Desempeño del modelo XGBoost sobre el IVF

El desempeño del modelo fue adecuado, con un R^2 cercano a 0.80 y un error bajo. Esto indica que el IVF puede ser aproximado de forma consistente a partir de variables socioeconómicas, laborales, educativas, digitales y de condiciones de vida.

El gráfico de importancia SHAP muestra que las variables más relevantes para explicar el IVF son empleo vulnerable, acceso digital, NBI, informalidad, ingreso, educación, categoría ocupacional y estado civil. Esto es coherente con la idea de que la vulnerabilidad financiera es multidimensional.




Figura 3: Importancia SHAP del modelo XGBoost sobre el IVF

Estos resultados deben interpretarse como una herramienta auxiliar de interpretación. SHAP no define los pesos del índice ni participa en su construcción; solo ayuda a identificar qué variables explican mejor el comportamiento del IVF en el modelo predictivo.

Robustez del índice

La estabilidad del IVF se evaluó mediante bootstrap simple con 200 iteraciones. La tabla muestra que el IVF medio es muy estable, ya que la media bootstrap es casi igual al valor final y el intervalo de confianza es estrecho.

Estadístico	Valor final	Media bootstrap	IC 95 %
IVF medio	0.4635	0.4636	[0.4635, 0.4637]
Perfil 1 (R_k)	0.5188	0.5040	[0.4748, 0.5542]
Perfil 2 (R_k)	0.3133	0.4013	[0.2416, 0.4437]
Perfil 3 (R_k)	0.5951	0.5895	[0.5402, 0.6051]
Perfil 4 (R_k)	0.4357	0.4460	[0.4164, 0.4665]
Perfil 5 (R_k)	0.5151	0.4736	[0.4464, 0.5053]

Tabla 5: Robustez bootstrap del IVF medio y de R_k por perfil ($B = 200$)

Esto indica que el índice agregado es consistente frente a variaciones de la muestra. En cambio, algunos niveles de vulnerabilidad por perfil presentan mayor variación, lo cual es esperable porque ciertos perfiles tienen menor tamaño o mayor heterogeneidad interna.

En general, el análisis de robustez respalda la estabilidad del IVF medio y permite usarlo como una medida confiable para comparar niveles de vulnerabilidad financiera dentro de la población no bancarizada.

CONCLUSIONES

Se construyó un Índice de Vulnerabilidad Financiera (IVF) continuo y probabilístico para personas no bancarizadas, coherente con la lógica de los índices compuestos multidimensionales propuesta por Nardo et al. (2005) y con la naturaleza multidimensional de la vulnerabilidad

financiera señalada por He y Zhou (2022) y Fernández-López y Álvarez-Espino (2024).

El uso del Análisis de Correspondencias Múltiples permitió transformar variables categóricas en dimensiones continuas, lo que resulta adecuado para datos socioeconómicos con múltiples categorías, como plantea Greenacre (2007). Esto facilitó la construcción de una matriz analítica consistente para la segmentación.

Los Modelos de Mixturas Gaussianas permitieron identificar cinco perfiles latentes de vulnerabilidad, incorporando la pertenencia probabilística de cada individuo. Este resultado coincide con McLachlan y Peel (2000), Biernacki et al. (2000) y Scrucca et al. (2016), quienes destacan la utilidad de los GMM y de criterios como BIC, ICL y entropía para clasificar poblaciones heterogéneas. A partir de la caracterización socioeconómica, los perfiles fueron interpretados como: vulnerabilidad laboral alta; menor vulnerabilidad relativa; vulnerabilidad estructural alta; vulnerabilidad intermedia con ingresos relativos altos; y vulnerabilidad material e informalidad alta.

El análisis auxiliar con XGBoost y valores SHAP mostró que el IVF se explica principalmente por empleo vulnerable, estado civil, acceso digital, NBI, informalidad, categoría ocupacional, edad, ingreso y nivel educativo. Estos resultados son coherentes con la naturaleza multidimensional de la vulnerabilidad financiera señalada por He y Zhou (2022) y Fernández-López y Álvarez-Espino (2024). Sin embargo, siguiendo a Lundberg y Lee (2017) y Bussmann et al. (2020), SHAP debe interpretarse como herramienta explicativa del modelo auxiliar, no como evidencia causal ni como ponderador del IVF.

La comparación entre modelos con y sin variables geográficas mostró que la

información territorial no mejora sustancialmente el desempeño predictivo, lo que respalda su exclusión en la construcción del GMM y del IVF. No obstante, las diferencias urbano-rurales evidencian que la geografía sigue siendo útil para caracterizar la vulnerabilidad posterior. A diferencia de enfoques centrados en inclusión financiera territorial, como Demirgüç-Kunt et al. (2022) y Allen et al. (2016), el IVF se asocia principalmente con condiciones individuales, laborales, educativas, digitales y materiales.

La evaluación de robustez mediante bootstrap simple con 200 iteraciones mostró estabilidad en el IVF medio ponderado, aunque los niveles R_k de algunos perfiles presentan mayor sensibilidad. Esto respalda el uso del índice como medida agregada, manteniendo una interpretación prudente de los valores específicos por perfil.

REFERENCIAS

- Arian, H., Seyfi, S. M., & Sharifi, A. (2020). Forecasting probability of default for consumer loan management with Gaussian mixture models. *arXiv: General Economics*.
<https://arxiv.org/abs/2011.07906>
- Banco Central de Reserva del Perú. (2024). Digitalización e inclusión financiera en Perú. *Revista Moneda*, 197, 14–20.
<https://www.bcrp.gob.pe/docs/Publicaciones/Revista-Moneda/moneda-197/moneda-197-02.pdf>
- Biernacki, C., Celeux, G., & Govaert, G. (2000). Assessing a Mixture Model for Clustering with the Integrated Completed Likelihood. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 22(7), 719–725.
<https://doi.org/10.1109/34.865189>

- Bussmann, N., Giudici, P., Marinelli, D., & Papenbrock, J. (2020). Explainable machine learning in credit risk management. *Computational Economics*, 57, 203–216.
<https://doi.org/10.1007/s10614-020-10042-0>
- Chen, X., Hu, G., & Wen, H. (2025). Investigating the factors influencing household financial vulnerability in China: An exploration based on the Shapley additive explanations approach. *Sustainability*.
<https://www.mdpi.com/2071-1050/17/12/5523>
- Demirgüç-Kunt, A., Klapper, L., Singer, D., & Ansar, S. (2022). *The Global Findex Database 2021: Financial inclusion, digital payments, and resilience in the age of COVID-19*. World Bank.
<https://doi.org/10.1596/978-1-4648-1897-4>
- He, L., & Zhou, S. (2022). Household financial vulnerability to income and medical expenditure shocks: Measurement and determinants. *International Journal of Environmental Research and Public Health*, 19(8), 4480.
<https://doi.org/10.3390/ijerph19084480>
- Hwang, Y., Lee, Y., & Fabozzi, F. J. (2022). Identifying household finance heterogeneity via deep clustering. *Annals of Operations Research*, 325, 1255–1289.
<https://doi.org/10.1007/s10479-022-04900-3>
- Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*.
<https://arxiv.org/pdf/1705.07874>
- Scrucca, L., Fop, M., Murphy, T. B., & Raftery, A. E. (2016). mclust 5: Clustering, classification and density estimation using Gaussian finite mixture models. *The R Journal*, 8(1), 289–317.
<https://doi.org/10.32614/RJ-2016-021>
- Superintendencia de Banca, Seguros y AFP. (2023). *Perú: Reporte de indicadores de inclusión financiera de los sistemas financiero, de seguros y de pensiones*. SBS.
https://www.sbs.gob.pe/app/stats_net/stats/EstadisticaSistemaFinancieroResultados.aspx?c=CIIF-0001
- Tan, B., Gan, Z., & Wu, Y. (2023). The measurement and early warning of daily financial stability index based on XGBoost and SHAP: Evidence from China. *Expert Systems with Applications*, 227, 120375.
<https://doi.org/10.1016/j.eswa.2023.120375>
- CAF - banco de desarrollo de América Latina y el Caribe, & Superintendencia de Banca, S. y A. (2025). Encuesta de Medición de Capacidades Financieras Perú 2022.
<https://scioteca.caf.com/handle/123456789/2528>
- Fernández-López, S., & Álvarez-Espino, M. Financial Vulnerability Of Low-Income Households: Review Of Scopus And Wos Journals And Future Research Agenda.
https://ideas.repec.org/a/eea/aeinde/v24y2024i1_9.html
- Greenacre, M. (2007). Correspondence Analysis in Practice (2nd ed.). Chapman and Hall/CRC.
<https://doi.org/10.1201/9781420011234>
- Instituto Nacional de Estadística e Informática. (2024). Encuesta Nacional de Hogares sobre Condiciones de Vida y Pobreza (ENAHO) 2024: Microdatos. INEI.
<https://proyectos.inei.gob.pe/microdatos/>
- McLachlan, G.J., & Peel, D. (2000). Finite Mixture Models. Wiley Series in

Probability and Statistics.
<https://doi.org/10.1002/0471721182>

<library/sites/geography/migrated/document/s/pfrc0403.pdf>

Nardo, M., Saisana, M., Saltelli, A., Tarantola, S., Hoffman, A.N., & Giovannini, E. (2005). Handbook on Constructing Composite Indicators: Methodology and User Guide.
https://www.oecd.org/content/dam/oecd/en/publications/reports/2008/08/handbook-on-constructing-composite-indicators-methodology-and-user-guide_g1gh9301/9789264043466-en.pdf

Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.
<https://dl.acm.org/doi/10.1145/2939672.2939785>

Shapley, L.S. (1988). A Value for n-person Games.
<https://doi.org/10.1017/CBO9780511528446.003>

Allen, F., Demirgüç-Kunt, A., Klapper, L., & Martinez Peria, M. S. (2016). The foundations of financial inclusion: Understanding ownership and use of formal accounts. Journal of Financial Intermediation, 27, 1–30.
<https://doi.org/10.1016/j.jfi.2015.12.003>

Cámara, N., & Tuesta, D. (2014). Measuring financial inclusion: A multidimensional index (Working Paper No. 14/26). BBVA Research.
https://www.bbvarsearch.com/wp-content/uploads/2014/09/WP14-26_Financial-Inclusion2.pdf

Kempson, E., McKay, S., & Willitts, M. (2004). Characteristics of families in debt and the nature of indebtedness (Research Report No. 211). Department for Work and Pensions.
<https://www.bristol.ac.uk/media->