

Universidad Nacional de Ingenieria
Facultad de Ingenieria Economica, Estadistica y CCSS
Escuela Profesional de Ingenieria Estadistica

Construccion de un Indice de Vulnerabilidad Financiera para personas no bancarizadas del Peru

Informe tecnico metodologico completo

Documento de respaldo: incluye procedimientos, variables
codificadas, recodificaciones, salidas del notebook, tablas y graficos

Alumno: Michael Sebastian Flores Quispe
Docente: Demetrio Antonio Ruiz Olorte
Asignatura: Investigacion Estadistica
Fuente de datos: ENAHO 2024, modulos 100, 200, 300 y 500
Notebook base: Construccion_IVF.ipynb

6 de julio de 2026

Índice

Índice de cuadros

Índice de figuras

Resumen ejecutivo

Este informe documenta, de forma detallada y reproducible, la construcción de un Índice de Vulnerabilidad Financiera (IVF) para personas no bancarizadas del Perú usando la ENAH0 2024. El flujo de trabajo parte de la integración de módulos de hogares, personas, educación y empleo; filtra a personas de 18 a 65 años no bancarizadas; limpia códigos centinela; recodifica variables; imputa valores faltantes; transforma variables categóricas con Análisis de Correspondencias Múltiples (MCA); estima perfiles latentes mediante Modelos de Mezclas Gaussianas (GMM); y construye un IVF continuo a partir de probabilidades posteriores de pertenencia a perfiles.

La versión documentada corrige una precisión metodológica importante: el GMM se ajusta directamente sobre la matriz individual procesada X_{gmm} . El factor de expansión FAC500A no entrena el GMM ni define un remuestreo ponderado. Se utiliza para calcular entropía/ICL aproximados, tamaños poblacionales, promedios ponderados por perfil, niveles R_k , IVF medio y distribuciones poblacionales. Asimismo, el bootstrap implementado es simple, con reemplazo y $B = 200$, y los pesos de expansión se usan después para resumir los resultados.

El resultado central es la identificación de cinco perfiles latentes. El Perfil 3 presenta el mayor nivel promedio de vulnerabilidad ($R_k = 0.5951$), mientras que el Perfil 2 presenta el menor ($R_k = 0.3133$). El IVF individual se calcula como:

$$IVF_i = \sum_{k=1}^K P(k | i) R_k,$$

donde $P(k | i)$ es la probabilidad posterior de que la persona i pertenezca al perfil k , y R_k es el nivel promedio ponderado de vulnerabilidad del perfil. XGBoost y SHAP se emplean como herramientas auxiliares de interpretación; no ponderan ni construyen el índice.

1. Planteamiento del estudio

1.1. Problema de investigación

La población no bancarizada no constituye un grupo homogéneo. Dentro de ella conviven personas con distintas combinaciones de bajos ingresos, informalidad laboral, menor educación, carencias materiales, baja conectividad digital y restricciones para acceder a mecanismos formales de ahorro o crédito. Por esta razón, una clasificación binaria no bancarizado/bancarizado resulta insuficiente para medir la vulnerabilidad financiera interna de este grupo.

La pregunta que guía el estudio es:

¿Cómo construir un Índice de Vulnerabilidad Financiera para personas no bancarizadas del Perú, utilizando información socioeconómica de la ENAH0 2024, que permita identificar perfiles latentes diferenciados mediante GMM e incorporar probabilísticamente la pertenencia de cada individuo a dichos perfiles?

1.2. Objetivo general

Construir un Índice de Vulnerabilidad Financiera para personas no bancarizadas del Perú, utilizando datos de la ENAH0 2024, a partir de perfiles latentes estimados mediante Modelos de Mezclas Gaussianas y probabilidades posteriores de pertenencia.

1.3. Objetivos especificos

1. Preparar la base analitica de personas no bancarizadas de 18 a 65 años a partir de la ENAH0 2024, construyendo variables socioeconomicas, laborales, educativas, digitales, financieras y de condiciones de vida relevantes para medir vulnerabilidad financiera.
2. Identificar perfiles latentes mediante Modelos de Mixturas Gaussianas, seleccionando el numero de perfiles con criterios de ajuste, clasificacion e interpretabilidad.
3. Construir el IVF como una medida continua y probabilistica, combinando probabilidades posteriores de pertenencia a perfiles con el nivel promedio de vulnerabilidad estimado para cada grupo.
4. Evaluar la coherencia empirica, interpretabilidad y estabilidad del IVF mediante caracterizacion socioeconomica y territorial, XGBoost, SHAP y bootstrap.

1.4. Alcance metodologico

El informe tiene dos niveles. Primero, presenta el procedimiento metodologico y los resultados principales. Segundo, incluye en los anexos las salidas literales de ejecucion por bloque del notebook, de modo que se preserve la trazabilidad entre codigo, tablas, graficos y narrativa. Las barras de progreso no analiticas de instalacion no se interpretan como resultados estadisticos.

1.5. Proposito de este informe frente al paper

Este documento no esta pensado como version final abreviada del articulo. Su funcion es servir como informe metodologico completo y como respaldo tecnico del paper: aqui se conserva el detalle que normalmente se recorta en un manuscrito academico, incluyendo la justificacion bibliografica de la construccion del indice, las variables originales codificadas, las recodificaciones, las decisiones de exclusion, las salidas de cada bloque del notebook y los graficos auxiliares. En el paper final pueden quedar solo los resultados centrales; este informe permite demostrar como se obtuvo cada componente.

2. Sustento bibliografico y logica de construccion del indice

2.1. Por que medir vulnerabilidad financiera de forma multidimensional

La vulnerabilidad financiera no se reduce al ingreso monetario observado en un momento del tiempo. En una persona no bancarizada, la fragilidad economica puede provenir simultaneamente de bajos ingresos, informalidad laboral, empleo vulnerable, baja educacion, necesidades basicas insatisfechas, limitado acceso digital y ausencia de mecanismos formales de ahorro o credito. Por ello, el indice se construye desde una perspectiva multidimensional: cada dimension captura una fuente distinta de exposicion al riesgo financiero o de menor capacidad de respuesta ante shocks.

Desde la literatura de vulnerabilidad financiera, esta decision se justifica porque los hogares o individuos vulnerables no solo enfrentan restricciones de liquidez, sino tambien limitaciones estructurales que reducen su capacidad de enfrentar gastos inesperados, desempleo, enfermedad o caidas de ingreso. Por tanto, el IVF no se plantea como un indice de pobreza ni como un indicador de bancarizacion; se plantea como una medida sintetica de fragilidad financiera dentro de la poblacion que ya fue filtrada como no bancarizada.

2.2. Por que usar la logica de indices compuestos

La construccion del IVF sigue la logica general de los indices compuestos: definir el fenomeno, seleccionar variables coherentes con el marco conceptual, tratar valores faltantes, normalizar indicadores, agregar dimensiones y evaluar robustez. Esta estructura es consistente con los lineamientos metodologicos para indices compuestos de Nardo et al. (2005), donde se recomienda que la agregacion sea transparente y que la interpretacion del indice dependa de un marco conceptual previo.

En el estudio, la agregacion no se realiza como una suma directa de todas las variables originales. Primero se usa el GMM para identificar perfiles latentes de vulnerabilidad; luego se calcula un nivel promedio de vulnerabilidad por perfil; finalmente se calcula el IVF individual combinando probabilidades posteriores con esos niveles de referencia. Esto convierte al IVF en un indice compuesto probabilistico.

2.3. Por que el indice no usa una asignacion rigida de perfiles

Una clasificacion rigida asignaria a cada individuo un unico perfil dominante y luego le atribuiria directamente el nivel promedio de vulnerabilidad de ese perfil. Esa estrategia pierde informacion, porque dos personas con el mismo perfil dominante pueden tener niveles distintos de cercania a otros perfiles. El GMM resuelve este problema mediante probabilidades posteriores de pertenencia. Si una persona se ubica cerca de la frontera entre dos perfiles, el indice refleja esa incertidumbre mediante una combinacion ponderada.

Matematicamente, si el GMM produce probabilidades posteriores $\tau_{ik} = P(k | i)$, estas cumplen:

$$0 \leq \tau_{ik} \leq 1, \quad \sum_{k=1}^K \tau_{ik} = 1.$$

Por eso pueden usarse como pesos probabilisticos en la construccion del indice.

2.4. Paso 1: construir un score auxiliar de vulnerabilidad V_i

El score auxiliar V_i resume seis dimensiones observables: ingreso, educacion, informalidad, NBI, empleo vulnerable y acceso digital. Su papel no es reemplazar al IVF ni definir directamente los perfiles; su papel es medir el nivel promedio de vulnerabilidad de cada perfil una vez que el GMM ya identifico los grupos latentes.

Las dimensiones protectoras se invierten para que todas apunten en la misma direccion: mayor valor significa mayor vulnerabilidad. Asi, ingreso, educacion y acceso digital se transforman en vulnerabilidad por menor ingreso, menor educacion y menor acceso digital. Las dimensiones de riesgo, como informalidad, NBI y empleo vulnerable, se mantienen en sentido directo. La forma general es:

$$V_i = \frac{1}{6} \left(v_i^{\text{ingreso}} + v_i^{\text{educacion}} + v_i^{\text{informalidad}} + v_i^{\text{NBI}} + v_i^{\text{empleo}} + v_i^{\text{digital}} \right).$$

Se usan ponderaciones iguales porque el trabajo no cuenta con una fuente externa que permita defender pesos diferenciales entre dimensiones. Esta decision favorece transparencia y replicabilidad. En un paper se puede resumir; en este informe se deja explicito que la ponderacion igual es una decision metodologica, no un resultado estimado.

2.5. Paso 2: calcular el nivel de vulnerabilidad del perfil R_k

Una vez asignado el perfil dominante del GMM, se calcula el nivel promedio de vulnerabilidad de cada perfil como media ponderada de V_i :

$$R_k = \frac{\sum_{i \in C_k} w_i V_i}{\sum_{i \in C_k} w_i},$$

donde C_k es el conjunto de personas cuyo perfil dominante es k y w_i es el factor de expansion FAC500A. Aquí el factor de expansion si es importante: no define el perfil ni entra como variable del GMM, pero permite que el nivel R_k represente mejor la composicion poblacional de la ENAH0.

2.6. Paso 3: construir el IVF individual mediante probabilidad total

El IVF individual se define como una esperanza condicional sobre los perfiles latentes:

$$IVF_i = \sum_{k=1}^K \tau_{ik} R_k.$$

Esta ecuacion puede leerse como una aplicacion de la logica del teorema de probabilidad total: el nivel individual de vulnerabilidad es la suma de los niveles posibles de vulnerabilidad por perfil, ponderados por la probabilidad de pertenencia a cada perfil. Si una persona pertenece casi con certeza al Perfil 3, su IVF se aproxima a R_3 . Si una persona tiene probabilidades repartidas entre varios perfiles, su IVF queda como un valor intermedio.

Por eso el IVF final es continuo y probabilistico. No es simplemente una etiqueta de cluster ni una suma simple de variables. Es una medida que combina: i) estructura latente estimada por GMM; ii) nivel promedio de vulnerabilidad de cada perfil; iii) incertidumbre de pertenencia individual.

2.7. Relacion entre bibliografia y decisiones metodologicas

Cuadro 1: Sustento bibliografico de las principales decisiones metodologicas

Decision metodologica	Uso dentro del estudio	Sustento conceptual
Medir vulnerabilidad como fenomeno multi-dimensional	El IVF incorpora ingreso, educacion, informalidad, empleo vulnerable, NBI y acceso digital.	Literatura sobre vulnerabilidad financiera y capacidad de respuesta ante shocks; enfoque multidimensional de hogares vulnerables.
Construir un indice compuesto	Se sintetizan varias dimensiones en una medida comparable entre individuos.	Nardo et al. (2005), lineamientos de indices compuestos.
Usar MCA antes del GMM	Las variables categoricas de encuesta se transforman en coordenadas continuas.	Greenacre (2007), analisis de correspondencias multiples para datos categoricos.
Usar GMM	Se identifican perfiles latentes con pertenencia probabilistica.	McLachlan y Peel (2000), modelos de mixturas finitas.
Usar BIC, ICL y entropia	Se selecciona K balanceando ajuste, parsimonia y nitidez de clasificacion.	Biernacki et al. (2000), ICL; Scrucca et al. (2016), mixtures y clustering.
Usar FAC500A despues del GMM	Se calculan tamanos poblacionales, R_k , medias ponderadas y caracterizacion.	Uso de factores de expansion en encuestas; el peso corrige la lectura poblacional, no define el perfil.
Usar XGBoost y SHAP como auxiliares	Se interpreta la coherencia empirica del IVF y de los perfiles, sin usarlos como ponderadores.	Chen y Guestrin (2016), XGBoost; Lundberg y Lee (2017), SHAP.

3. Datos, modulos y poblacion objetivo

3.1. Fuente de datos

Se utilizaron microdatos de la Encuesta Nacional de Hogares 2024. El panel individual se construyo integrando los modulos de vivienda/hogar, personas, educacion y empleo/ingresos. La unidad de analisis final es la persona no bancarizada entre 18 y 65 años.

Cuadro 2: Modulos ENAH0 utilizados y funcion dentro del estudio

Modulo	Archivo	Funcion en el estudio
100	Enaho01-2024-100.csv	Variables del hogar, vivienda, NBI, geografia, acceso digital y dificultad de pago asociada a vivienda/credito.
200	Enaho01-2024-200.csv	Variables individuales: sexo, edad y estado civil.
300	Enaho01A-2024-300.csv	Variables educativas: nivel educativo y alfabetismo.
500	Enaho01a-2024-500.csv	Variables laborales, ingresos, inclusion financiera, motivos de no tenencia de cuenta/credito, ahorro informal y factor de expansion FAC500A.

3.2. Integracion y filtro

El modulo 500 se uso como base individual; luego se incorporaron los modulos 200 y 300 por identificador de persona y el modulo 100 por identificador de hogar. El filtro de poblacion objetivo fue:

$$P558E1_6 = 6 \quad y \quad 18 \leq P208A \leq 65.$$

En la ejecucion, el panel inicial tuvo 85,992 personas. Luego del filtro, la base analitica incluye 29,954 personas no bancarizadas de 18 a 65 años, equivalente al 34.8 % del panel integrado.

Cuadro 3: Tamaño de base y filtro de poblacion objetivo

Indicador	Valor
Personas en modulo base 500	85,992
Personas en panel integrado	85,992
Personas sin match en modulo 200	0
Personas no bancarizadas de 18 a 65 años	29,954
Proporcion sobre panel total	34.8 %

4. Diccionario operativo: variables codificadas, renombradas y recodificadas

4.1. Variables seleccionadas

La Tabla ?? resume los codigos originales de ENAH0, los nombres internos usados en Python, las transformaciones y el rol analitico. Esta tabla es clave para entender como el codigo pasa de variables codificadas a variables recodificadas, compuestas o excluidas del modelo principal.

Cuadro 4: Diccionario operativo de variables seleccionadas y recodificadas

Codigo ENAH0	Nombre interno	Dimension	Tratamiento y uso
P558E1_6	filtro no bancarizado	Inclusion financiera	Se usa para filtrar poblacion objetivo. La condicion usada fue $P558E1_6 == 6$. No entra al GMM ni al IVF.

Codigo ENAHO	Nombre interno	Dimension	Tratamiento y uso
P207	sexo	Sociodemografica	Recodificado: 1 = Hombre, 2 = Mujer. Entra a MCA y XGBoost; tambien caracteriza perfiles.
P208A	edad	Sociodemografica	Variable continua. Entra a VARS_CONT y por tanto a X_gmm; tambien entra a XGBoost.
P209	estado_civil	Sociodemografica	Recodificado a Conviviente, Casado/a, Viudo/a, Divorciado/a, Separado/a y Soltero/a. Entra a MCA y XGBoost.
DOMINIO	dominio / dominio_macro	Geografica	dominio se usa como predictor auxiliar en MICE del ingreso. dominio_macro se usa para caracterizacion territorial y XGBoost comparativo, no directamente para GMM ni IVF.
ESTRATO	estrato / area / tamano_poblacional	Geografica	estrato se usa como predictor auxiliar en MICE del ingreso. Se recodifica a urbano/rural y tamaño poblacional. No entra directamente a X_gmm.
UBIGE0	ubigeo	Geografica	Conservado como identificador territorial. No se usa en X_gmm.
P301A	nivel_educativo	Educativa	Se recodifica a nivel_educativo_ord y nivel_educativo_cat. La version ordinal entra a VARS_CONT y Vi; la categorica se conserva para perfilado.
P302	alfabetismo	Educativa	Excluida del modelo principal por alta proporcion de missing. Puede usarse solo descriptivamente si se decide reportarla.
P507	categoria_ocupacional / P507_raw	Laboral	Se recodifica a Empleado, Independiente, Empleado, Obrero, TFNR, Trabajador del hogar y Otro. Entra a MCA y XGBoost. De sus codigos originales se derivan informalidad y empleo_vulnerable.
P511A	tipo_contrato / P511A_raw	Laboral	No entra a MCA por missing alto; se usa en la regla de informalidad mediante el codigo original.
P512A	tamano_empresa	Laboral	Imputada con MICE. Usada como predictor auxiliar en la imputacion MICE del ingreso.
P524A1	ingreso_dep	Economica	Ingreso de trabajo dependiente. El centinela 999999 se transforma a NaN. Entra en la construccion de ingreso.
P530A	ingreso_ind	Economica	Ganancia neta de trabajo independiente. El centinela 999999 se transforma a NaN. Entra en la construccion de ingreso.
P558A5	sin_pension	Laboral/seguridad social	Entra en XGBoost como predictor auxiliar.
P558C	etnia	Sociodemografica	Imputada mediante imputacion simple por mediana. Entra en XGBoost.
NBI1	nbi_vivienda_inadecuada	Condiciones de vida	Componente de nbi_score.
NBI2	nbi_hacinamiento	Condiciones de vida	Componente de nbi_score.
NBI3	nbi_sin_sshh	Condiciones de vida	Componente de nbi_score.
NBI4	nbi_ninos_sin_escuela	Condiciones de vida	Componente de nbi_score.
NBI5	nbi_alta_dependencia	Condiciones de vida	Componente de nbi_score.
P558F1A	razon_sin_cuenta	Inclusion financiera	Variable categorica para MCA; caracteriza motivos de no tenencia de cuenta.
P558F1B	razon_sin_credito	Inclusion financiera	Variable categorica para MCA; imputada simple cuando faltaba.
P558G1	ahorro_junta	Conductas financieras	Variable categorica para MCA.
P558G2	ahorro_conocidos	Conductas financieras	Variable categorica para MCA.
P558G3	ahorro_casa	Conductas financieras	Variable categorica para MCA.
P558G5	no_ahorro_ni_presto	Conductas financieras	Se conserva como variable disponible; no quedo en VARS_MCA final.
P558G6	presto_dinero	Conductas financieras	Se conserva como variable disponible; no quedo en VARS_MCA final.
P558G7	recibio_prestamo_informal	Conductas financieras	Variable categorica para MCA.
P558G8	ahorro_banco	Conductas financieras	Se conserva como variable disponible; no quedo en VARS_MCA final.
P1142	tiene_computadora	Acceso digital	Componente binario de acceso_digital.
P1144	tiene_internet	Acceso digital	Componente binario de acceso_digital.
P1144B1, P1144B2, P1144B3	banda_ancha, cable, movil	Acceso digital	Variables solicitadas pero no encontradas en el modulo cargado; por ello el componente de conexion avanzada no apor to variacion observada.
P1145	usa_internet_personal	Acceso digital	Componente binario de acceso_digital.

Codigo ENAHO	Nombre interno	Dimension	Tratamiento y uso
P107B1	dificultad_pago_cuota	Credito/vivienda	Componente de dificultad_pago_credito.
P107B2	atraso_pago	Credito/vivienda	Componente de dificultad_pago_credito.
P107B3	renegocio_deuda	Credito/vivienda	Componente de dificultad_pago_credito.
P107B4	perdio_garantia	Credito/vivienda	Componente de dificultad_pago_credito.
P107E	deuda_pendiente_vivienda	Credito/vivienda	Excluida de dificultad_pago_credito por missing extremadamente alto.
FAC500A	factor_expansion factor_raw	/ Ponderacion	Factor de expansion. No entra al GMM; se usa para estimaciones poblacionales, R_k , IVF medio, entropia/ICL aproximados y resumen bootstrap.

4.2. Tratamiento de codigos centinela

El primer paso de limpieza transformo codigos no validos o de no respuesta a valores faltantes. Esta decision evita que codigos administrativos, como 9, 99 o 999999, sean interpretados como valores numericos reales por la imputacion, MCA, GMM o modelos supervisados.

Cuadro 5: Codigos centinela transformados a valores faltantes

Variable interna	Codigo centinela	Observacion
Variables categoricas generales	9	Estado civil, educacion, alfabetismo, ocupacion, contrato, tamaño de empresa, pension, etnia, dominio, estrato, acceso digital y credito.
Motivos sin cuenta sin credito	/ 99 y 9	Se consideran no respuesta o codigo no valido.
ingreso_dep ingreso_ind	y 999999	Se interpreta como no declaracion de ingreso y se envia a NaN antes de construir ingreso total.

En la ejecucion se detectaron variables no disponibles en el panel: P1144B1, P1144B2 y P1144B3. Ademias, se convirtieron a NaN 1,371 centinelas de nivel educativo, 13 de alfabetismo, 53 de etnia, 583 de razon sin credito, 71 de ingreso dependiente y 1,804 de ingreso independiente.

5. Limpieza, imputacion y recodificaciones

5.1. Diagnostico de valores faltantes

Las variables con mas de 5 % de valores faltantes se trataron mediante MICE, excepto aquellas excluidas por decision metodologica. Las variables con missing menor o igual a 5 % se imputaron con mediana o moda segun su tipo. La Tabla ?? resume la salida del diagnostico.

Cuadro 6: Tratamiento de valores faltantes

Variable	% missing	N missing	Metodo
tamano_empresa	21.62	6,476	MICE
categoria_ocupacional	21.61	6,472	MICE
nivel_educativo	4.58	1,371	imputacion simple
razon_sin_credito	2.11	633	imputacion simple

Variable	% missing	N missing	Metodo
etnia	0.18	53	imputacion simple
Resto de variables incluidas	0.00	0	sin missings




Figura 1: Porcentaje de valores faltantes por variable. Las barras rojas superan el umbral de MICE de 5 %.

La imputacion simple uso mediana para nivel_educativo, razon_sin_credito y etnia. MICE se aplico a tamano_empresa y categoria_ocupacional. Al final del bloque no quedaron valores faltantes en las variables consideradas para esta etapa, excluyendo ingreso, que tuvo un tratamiento propio.

5.2. Variables excluidas del MICE general

No todas las variables con missing se imputaron en el MICE general. Las exclusiones se justifican por su funcion dentro del flujo:

- ingreso_dep y ingreso_ind: tienen logica propia de construccion de ingreso total en el Bloque 9.
- factor_expansion: es peso muestral, no predictor sustantivo de vulnerabilidad.
- ubigeo, dominio y estrato: se reservan para geografia; dominio y estrato se usan luego como predictores auxiliares del ingreso.
- alfabetismo: 78.3 % missing; se excluye del modelo principal.
- tipo_contrato: 63.4 % missing; se usa solo como fuente para la regla de informalidad mediante P511A_raw.
- deuda_pendiente_vivienda: 97.5 % missing; se excluye de dificultad_pago_credito.

5.3. Recodificacion geografica

Las variables geograficas no entran directamente en X_{gmm} , en el GMM ni en el IVF. Sin embargo, dominio y estrato si se usan como predictores auxiliares en la imputacion MICE del ingreso. Luego, area, dominio_macro y tamano_poblacional sirven para caracterizacion territorial posterior y comparaciones auxiliares con XGBoost.

Cuadro 7: Recodificacion territorial

Variable original	Variable recodificada	Regla
ESTRATO	area	1 a 6 = Urbano; 7 y 8 = Rural.
ESTRATO	tamano_poblacional	1-2 Ciudad grande; 3-4 Ciudad mediana; 5-6 centro poblado pequeño; 7-8 Rural.
DOMINIO	dominio_macro	1-3 Costa; 4-6 Sierra; 7 Selva; 8 Lima Metropolitana.

En la muestra analítica, 19,204 observaciones quedaron en area urbana y 10,750 en area rural. Por dominio macro, se registraron 11,042 en Sierra, 9,081 en Costa, 7,346 en Selva y 2,485 en Lima Metropolitana.

5.4. Variables digitales y dificultad de pago

El score `acceso_digital` se construyo sumando componentes binarios: tenencia de computadora, tenencia de internet, conexion avanzada y uso personal de internet. Conceptualmente el rango es 0 a 4; sin embargo, en esta base las variables P1144B1, P1144B2 y P1144B3 no fueron encontradas, por lo que la variacion observada quedo entre 0 y 2.

Cuadro 8: Construcccion de variables compuestas digitales y de credito

Variable compuesta	Componentes	Uso final
<code>acceso_digital</code>	<code>tiene_computadora</code> , <code>tiene_internet</code> , <code>conexion_avanzada</code> , <code>usa_internet_personal</code>	Entra a <code>VARS_CONT</code> , <code>Vi</code> y <code>XGBoost</code> . Valores observados: 0, 1 y 2.
<code>dificultad_pago_credito</code>	<code>dificultad_pago_cuota</code> , <code>atraso_pago</code> , <code>renegocio_deuda</code> , <code>perdio_garantia</code>	Evaluada inicialmente. En la base resultado constante en 4; no entra a <code>Vi</code> ni a <code>X_gmm</code> .

La variable `dificultad_pago_credito` quedo con 29,954 casos en el valor 4, por lo que no aporta variabilidad para segmentacion o construccion del score auxiliar.

5.5. Recodificacion socioeconomica

La Tabla ?? resume las principales recodificaciones socioeconomicas.

Cuadro 9: Reglas de recodificacion socioeconomica

Variable final	Fuente	Regla
<code>sexo</code>	P207	1 = Hombre; 2 = Mujer.
<code>estado_civil</code>	P209	1 Conviviente; 2 Casado/a; 3 Viudo/a; 4 Divorciado/a; 5 Separado/a; 6 Soltero/a.
<code>nivel_educativo_ord</code>	P301A	1 -> 0; 2 -> 1; 3 -> 2; 4 -> 3; 5 -> 4; 6 -> 5; 7 -> 6; 8 -> 7; 9 -> 8; 10 -> 9; 11 -> 10; 12 -> 0.

Variable final	Fuente	Regla
nivel_educativo_cat	nivel_educativo_ord	Sin nivel, Inicial, Primaria incompleta/completa, Secundaria incompleta/completa, Superior no universitaria incompleta/completa, Superior universitaria incompleta/completa, Maestria/doctorado.
categoria_ocupacional	P507_raw	1 Empleador; 2 Independiente; 3 Empleado; 4 Obrero; 5 TFNR; 6 Trabajador del hogar; 7 Otro.
informalidad	P507_raw, P511A_raw	1 si ocupacion es independiente, TFNR o trabajador del hogar, o si P511A_raw == 7; 0 en caso contrario.
empleo_vulnerable	P507_raw	1 si ocupacion es independiente o TFNR; 0 en caso contrario.
nbi_score	NBI1 a NBI5	Suma de cinco necesidades basicas insatisfechas, con faltantes tratados como 0.
ingreso	P524A1, P530A, P507_raw	Dependientes usan ingreso dependiente; independientes usan ganancia independiente; TFNR conservan 0 genuino; faltantes reales se imputan con MICE en log-ingreso.

La muestra presenta 15,722 mujeres y 14,232 hombres. Antes de imputar ingreso, 17,439 personas tenian ingreso real positivo, 4,041 eran TFNR con cero genuino y 8,474 requerian imputacion. La mediana del ingreso real fue S/ 370, mientras que la mediana del ingreso imputado fue S/ 885. Luego de la imputacion, la mediana del ingreso final fue S/ 362.

5.6. Imputacion MICE del ingreso

La imputacion del ingreso se realizo en escala logaritmica para reducir el efecto de asimetria. Los predictores usados fueron nivel_educativo_ord, categoria_ocupacional, tamano_empresa, informalidad, empleo_vulnerable, nbi_score, dominio y estrato. La precision importante es que los TFNR conservan ingreso final 0; aunque se marquen como faltantes en la variable logaritmica interna, cualquier imputacion generada para ellos se descarta y se reinserta el cero genuino.

6. Matriz analitica para segmentacion

6.1. Separacion de variables

La matriz de segmentacion no utiliza todas las variables disponibles. Para evitar redundancia, algunas variables se conservan para perfilado, Vi o XGBoost, pero no se incluyen como columnas directas de X_gmm.

Cuadro 10: Variables por funcion analitica

Grupo	Variables	Funcion
VARs_MCA	sexo, estado_civil, categoria_ocupacional, razon_sin_cuenta, razon_sin_credito, ahorro_junta, ahorro_conocidos, ahorro_casa, recibio_prestamo_informal	Se transforman con MCA para obtener coordenadas continuas.
VARs_CONT	edad, nivel_educativo_ord, ingreso, nbi_score, acceso_digital	Se estandarizan y se concatenan con coordenadas MCA para formar X_{gmm} .
VARs_PERFILADO_EXTRA	nivel_educativo_cat, informalidad, empleo_vulnerable	No entran a X_{gmm} ; se usan para perfilado post-GMM. Informalidad y empleo vulnerable tambien entran a V_i y XGBoost.
VARs_GEO	area, dominio_macro, tamano_poblacional	No entran directamente a GMM ni IVF; se usan para caracterizacion territorial y modelos comparativos.

La matriz final X_{gmm} tuvo 29,954 filas y 17 columnas: 12 dimensiones MCA y 5 variables continuas estandarizadas.

6.2. Analisis de Correspondencias Multiples

El MCA transformo variables categoricas en coordenadas continuas. Se retuvieron 12 dimensiones, el numero minimo necesario para superar el 50 % de inercia acumulada.

Cuadro 11: Inercia por dimension MCA

Componente	Eigenvalue	% varianza	% acumulado
0	0.222	6.90	6.90
1	0.164	5.10	12.00
2	0.151	4.68	16.68
3	0.134	4.17	20.85
4	0.133	4.13	24.98
5	0.125	3.88	28.86
6	0.119	3.70	32.56
7	0.118	3.66	36.22
8	0.115	3.57	39.79
9	0.114	3.53	43.32
10	0.113	3.52	46.84
11	0.113	3.51	50.36
12	0.112	3.48	53.83
13	0.111	3.45	57.28
14	0.110	3.42	60.71
15	0.110	3.42	64.12
16	0.109	3.39	67.51
17	0.108	3.34	70.85




Figura 2: Inercia acumulada del MCA. La línea horizontal marca el umbral de 50 % y la línea vertical indica las 12 dimensiones retenidas.

7. Score auxiliar de vulnerabilidad y factor de expansion

7.1. Construcción del score V_i

El score V_i no reemplaza al GMM ni es la variable dependiente del XGBoost Regressor. Su función es servir de ancla para estimar R_k , el nivel promedio de vulnerabilidad de cada perfil. Se construye con seis indicadores normalizados:

- ingreso, invertido porque mayor ingreso implica menor vulnerabilidad;
- nivel educativo ordinal, invertido porque mayor educacion implica menor vulnerabilidad;
- informalidad, directo;
- NBI, directo;
- empleo vulnerable, directo;
- acceso digital, invertido porque mayor acceso implica menor vulnerabilidad.

Si z_{ij} representa el indicador normalizado de la dimension j , entonces:

$$V_i = \frac{1}{6} \sum_{j=1}^6 z_{ij}.$$

La ponderacion igual se utiliza por transparencia y replicabilidad, evitando imponer pesos arbitrarios. La variable dificultad_pago_credito fue evaluada pero se excluyo por variabilidad nula/baja en la base analítica.

Cuadro 12: Estadísticas descriptivas del score auxiliar V_i

Estadístico	Valor
N	29,954
Media	0.491
Desviacion estandar	0.160
Minimo	0.105
P25	0.366
Mediana	0.564
P75	0.617
Maximo	0.917




Figura 3: Distribucion del score auxiliar V_i .

7.2. Uso de FAC500A

El factor de expansion FAC500A representa la expansion poblacional de cada observacion. En la base analítica, su suma fue 9,243,595. Su uso en el pipeline es posterior o auxiliar: no

entra como variable del GMM ni define una pseudo-muestra de entrenamiento. Se usa para entropia/ICL ponderados, calculo de R_k , IVF medio ponderado, distribuciones de perfiles y resumen de robustez.

8. Modelos de Mixturas Gaussianas y seleccion de perfiles

8.1. Modelo GMM

Un GMM representa la distribucion de los datos como mezcla de K componentes gaussianos:

$$p(x_i) = \sum_{k=1}^K \pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k),$$

donde π_k es el peso de mezcla, μ_k la media y Σ_k la matriz de covarianzas del componente k . La ventaja para este estudio es que cada persona recibe probabilidades posteriores de pertenencia:

$$P(k | i) = \frac{\pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k)}{\sum_{h=1}^K \pi_h \mathcal{N}(x_i | \mu_h, \Sigma_h)}.$$

Estas probabilidades permiten medir vulnerabilidad de forma continua, especialmente en personas ubicadas entre perfiles.

8.2. Criterios de seleccion de K

Se estimaron GMM para $K = 2, 3, 4, 5$. El criterio principal fue ICL, que penaliza el BIC por incertidumbre de clasificacion. Tambien se uso entropia relativa como indicador de nitidez de asignacion.

Cuadro 13: Comparacion de modelos GMM por BIC, ICL y entropia

K	BIC	ICL	Entropia	E/ln(K)	Converge
2	10,526.1	10,602.0	0.0013	0.0018	True
3	-295,630.9	-295,501.6	0.0022	0.0020	True
4	-500,435.8	-500,341.3	0.0016	0.0011	True
5	-604,821.4	-604,423.0	0.0066	0.0041	True

Tanto BIC como ICL seleccionaron $K = 5$. La entropia relativa fue baja en todos los casos, y el modelo de cinco perfiles permitio diferenciar grupos socioeconomicos interpretables sin fragmentar excesivamente la poblacion.




Figura 4: Selección de K según BIC, ICL y entropía relativa.

8.3. Modelo final

El GMM final se reestimo con $K = 5$ y $n_{init}=20$. No se reutilizo ninguna pseudo-muestra ni se aplico remuestreo ponderado. La salida final fue:

Cuadro 14: Resumen del GMM final

Indicador	Valor
K final	5
Convergencia	True
BIC	-627,028.6
ICL	-623,086.5
Entropia media	0.0658
Entropia relativa	0.0409
Calidad de clasificacion	Optima (< 0.15)

Cuadro 15: Distribucion de perfiles: muestra y poblacion expandida

Perfil	Observaciones	Poblacion expandida
Perfil 1	12,810	3,767,383
Perfil 2	5,451	2,096,007
Perfil 3	2,218	519,269
Perfil 4	4,178	1,364,805
Perfil 5	5,297	1,496,131

9. Construccion del IVF

9.1. Calculo de R_k

Para cada perfil, se calculo el promedio ponderado de V_i con FAC500A. Este promedio representa el nivel de vulnerabilidad del perfil en terminos poblacionales:

$$R_k = \frac{\sum_{i \in C_k} w_i V_i}{\sum_{i \in C_k} w_i},$$

donde w_i es FAC500A. El orden de vulnerabilidad obtenido fue Perfil 3, Perfil 1, Perfil 5, Perfil 4 y Perfil 2.

Cuadro 16: Niveles promedio de vulnerabilidad por perfil R_k

Perfil	R_k	Observaciones	Poblacion expandida
Perfil 1	0.5188	12,810	3,767,383
Perfil 2	0.3133	5,451	2,096,007
Perfil 3	0.5951	2,218	519,269
Perfil 4	0.4357	4,178	1,364,805
Perfil 5	0.5151	5,297	1,496,131

9.2. Indice individual

El IVF individual combina las probabilidades posteriores del GMM con los niveles R_k :

$$IVF_i = \sum_{k=1}^5 P(k | i) R_k.$$

Esta formulacion evita asignar un nivel completamente rigido a las personas que estan en la frontera entre perfiles.

Cuadro 17: Estadisticas descriptivas del IVF

Estadistico	Valor
N	29,954
Media simple	0.4747
Desviacion estandar	0.0845
Minimo	0.3133
P25	0.4357
Mediana	0.5160
P75	0.5188
Maximo	0.5951
Media ponderada	0.4635




Figura 5: Distribucion general del IVF y distribucion por perfil dominante.

10. Caracterizacion socioeconomica de perfiles

10.1. Variables retiradas de X_gmm y perfilado posterior

nivel_educativo_cat, informalidad y empleo_vulnerable se retiraron de X_gmm por redundancia. Esto no significa que se descarten del analisis: nivel_educativo_cat se usa para perfilado, mientras que informalidad y empleo_vulnerable participan en Vi, caracterizacion y XGBoost. La salida de perfilado muestra que estas variables, aunque no fueron columnas del GMM, separan de manera informativa a los perfiles.




Figura 6: Distribucion por perfil de variables retiradas de X_gmm: nivel educativo categorico, informalidad y empleo vulnerable.

10.2. Resumen socioeconomico ponderado

Cuadro 18: Caracterizacion socioeconomico de perfiles, estadísticas ponderadas por FAC500A

Variable	Perfil 1	Perfil 2	Perfil 3	Perfil 4	Perfil 5
n muestra	12,810	5,451	2,218	4,178	5,297
n poblacion	3,767,382	2,096,006	519,269	1,364,805	1,496,130
IVF medio	0.5185	0.3133	0.5951	0.4359	0.5150
Vi medio	0.5188	0.3133	0.5951	0.4357	0.5151
Rk	0.5188	0.3133	0.5951	0.4357	0.5151
Ingreso medio	624.0	1,037.5	569.8	1,089.9	585.4
Edad media	44.1	31.1	43.4	40.5	38.8
NBI medio	0.000	0.000	0.419	0.353	0.922
Proporcion informal	0.829	0.394	0.770	0.684	0.779
Proporcion empleo vulnerable	0.724	0.000	0.542	0.353	0.501
Educacion ordinal media	4.09	4.62	3.40	4.56	3.91
Acceso digital medio	2.000	2.000	0.953	2.000	2.000
Proporcion mujer	0.562	0.468	0.447	0.515	0.439




Figura 7: Heatmap de caracterizacion socioeconomico. Las anotaciones muestran valores reales; el color representa normalizacion por fila.

10.3. Lectura sustantiva de perfiles

- **Perfil 1:** vulnerabilidad alta. Presenta informalidad y empleo vulnerable elevados, con NBI medio igual a cero. Su vulnerabilidad proviene sobre todo de condiciones laborales.

- **Perfil 2:** perfil menos vulnerable. Tiene mayor ingreso promedio, mayor educacion, baja informalidad relativa y ausencia de empleo vulnerable.
- **Perfil 3:** perfil mas vulnerable. Combina menor educacion, bajo acceso digital y presencia relevante de NBI.
- **Perfil 4:** vulnerabilidad intermedia. Presenta ingresos altos en promedio, pero conserva NBI e informalidad.
- **Perfil 5:** vulnerabilidad alta-media. Se asocia principalmente al mayor NBI promedio y alta informalidad.

11. Caracterizacion territorial posterior

11.1. Distribucion por area, dominio y tamaño poblacional

La geografia no define directamente los perfiles ni el IVF, pero permite interpretar su distribucion espacial. La Tabla ?? muestra que los perfiles 3 y 5 tienen mayor presencia relativa rural que los perfiles menos vulnerables.

Cuadro 19: Distribucion ponderada por area dentro de cada perfil

Area	Perfil 1	Perfil 2	Perfil 3	Perfil 4	Perfil 5
Urbano	0.772	0.886	0.607	0.837	0.676
Rural	0.228	0.114	0.393	0.163	0.324




Figura 8: Composicion urbano-rural por perfil.

Cuadro 20: Distribucion ponderada por dominio macro dentro de cada perfil

Dominio	Perfil 1	Perfil 2	Perfil 3	Perfil 4	Perfil 5
Sierra	0.423	0.287	0.301	0.292	0.348
Selva	0.105	0.079	0.296	0.187	0.271
Costa	0.241	0.280	0.202	0.259	0.231
Lima Metropolitana	0.231	0.353	0.201	0.262	0.150




Figura 9: Composicion por dominio macro dentro de cada perfil.

Cuadro 21: Distribucion ponderada por tamaño poblacional dentro de cada perfil

Tamaño poblacional	Perfil 1	Perfil 2	Perfil 3	Perfil 4	Perfil 5
Ciudad mediana	0.125	0.120	0.076	0.140	0.133
CP pequeño	0.222	0.182	0.184	0.159	0.201
Rural	0.228	0.114	0.393	0.163	0.324
Ciudad grande	0.425	0.584	0.347	0.539	0.342




Figura 10: Composicion por tamaño poblacional dentro de cada perfil.

11.2. IVF por dominio macro

El IVF medio ponderado fue 0.4738 en Sierra, 0.4858 en Selva, 0.4564 en Costa y 0.4426 en Lima Metropolitana. Esta lectura confirma que el indice captura una dimension territorial posterior sin haber usado geografia directamente para formar perfiles.


12. Modelos auxiliares XGBoost y SHAP

12.1. Clasificación de perfiles sin geografía


El primer modelo XGBoost clasificó el perfil dominante usando variables individuales y socioeconómicas, excluyendo geografía. FAC500A se usó como `sample_weight`; esto incorpora ponderación de expansión, pero no equivale a estimar toda la varianza del diseño muestral complejo.

Cuadro 22: Desempeño del XGBoost clasificador sin geografía

Clase	Precision	Recall	F1-score	Support
Perfil 1	0.87	0.94	0.90	2,562
Perfil 2	0.84	1.00	0.92	1,090
Perfil 3	1.00	1.00	1.00	444
Perfil 4	0.96	0.38	0.55	836
Perfil 5	0.81	0.87	0.84	1,059
Accuracy			0.87	5,991
Macro avg	0.90	0.84	0.84	5,991
Weighted avg	0.88	0.87	0.85	5,991



(a) Matriz de confusión sin geografía.



(b) SHAP sin geografía.

Figura 11: XGBoost clasificador sin variables geográficas.

12.2. Clasificación de perfiles con geografía

El segundo modelo agrega `area`, `dominio_macro` y `tamano_poblacional`. El desempeño global se mantiene prácticamente igual, lo que respalda que la geografía funcione mejor como caracterización territorial posterior que como insumo directo del IVF.

Cuadro 23: Desempeño del XGBoost clasificador con geografia

Clase	Precision	Recall	F1-score	Support
Perfil 1	0.86	0.95	0.90	2,562
Perfil 2	0.85	1.00	0.92	1,090
Perfil 3	1.00	1.00	1.00	444
Perfil 4	0.97	0.38	0.55	836
Perfil 5	0.81	0.86	0.84	1,059
Accuracy			0.87	5,991
Macro avg	0.90	0.84	0.84	5,991
Weighted avg	0.88	0.87	0.85	5,991




Figura 12: XGBoost clasificador con variables geograficas.

12.3. Comparacion SHAP sin/con geografia

Las variables socioeconomicas principales conservan su importancia al agregar geografia. Las variables geograficas exclusivas tienen importancia comparativamente menor.

Cuadro 24: Importancia media absoluta SHAP: comparacion sin y con geografia

Variable	Sin geografia	Con geografia
acceso_digital	1.5042	1.5039
empleo_vulnerable	0.9368	0.8987
nbi_score	0.7978	0.7881
estado_civil_Conviviente	0.2196	0.2112
estado_civil_Soltero/a	0.1908	0.2186
categoria_ocupacional_Obrero	0.1395	0.1373
informalidad	0.1321	0.1248
ingreso	0.0915	0.0811
edad	0.0713	0.0749
estado_civil_Separado/a	0.0702	0.0583
nivel_educativo_ord	0.0588	0.0525
categoria_ocupacional_Empleador	0.0579	0.0573
etnia	0.0512	0.0487
estado_civil_Viudo/a	0.0445	0.0411
categoria_ocupacional_Trab_hogar	0.0370	0.0364
sin_pension	0.0208	0.0176
sexo_Mujer	0.0123	0.0064
estado_civil_Divorciado/a	0.0072	0.0070
categoria_ocupacional_Otro	0.0059	0.0058
categoria_ocupacional_Independiente	0.0019	0.0014
dificultad_pago_credito	0.0000	0.0000
categoria_ocupacional_TFNR	0.0000	0.0000

Cuadro 25: Variables geograficas exclusivas en el modelo con geografia

Variable	Importancia SHAP
area_Urbano	0.0292
dominio_macro_Lima Metropolitana	0.0277
tamano_poblacional_Ciudad grande	0.0231
dominio_macro_Sierra	0.0212
dominio_macro_Selva	0.0137
tamano_poblacional_Ciudad mediana	0.0102
tamano_poblacional_Rural	0.0000




Figura 13: Comparacion SHAP entre modelos sin y con geografia.

12.4. XGBoost Regressor para explicar el IVF

El XGBoost Regressor usa el IVF continuo como variable dependiente. Obtuvo RMSE = 0.0375 y $R^2 = 0.7996$. Esto indica que las variables individuales reconstruyen razonablemente el indice, lo cual respalda su coherencia empirica. Sin embargo, no debe interpretarse como validacion causal.

Cuadro 26: Desempeño del XGBoost Regressor sobre el IVF

Metrica	Valor
RMSE	0.0375
R^2	0.7996
Importancia SHAP de estado civil agrupado	0.0368
Importancia SHAP de edad	0.0024




Figura 14: Resumen SHAP del XGBoost Regressor sobre el IVF.




Figura 15: Importancia SHAP media absoluta del XGBoost Regressor sobre el IVF.




Figura 16: Importancia SHAP con dummies de estado civil agrupadas.




Figura 17: Valores SHAP del XGBoost Regressor sobre el IVF, desagregados por perfil GMM.




Figura 18: Importancia SHAP media absoluta por perfil, con estado civil agrupado.

13. Heterogeneidad urbano-rural

13.1. IVF medio y distribucion de perfiles por area

El IVF medio ponderado fue mayor en area rural que urbana. Esto no significa que la geografia haya construido el indice, sino que la vulnerabilidad estimada se distribuye de manera distinta por area.

Cuadro 27: IVF y V_i medios ponderados por area

Area	IVF medio	V_i medio	Poblacion expandida
Urbano	0.4557	0.4374	7,236,591
Rural	0.4920	0.5583	2,007,004

Cuadro 28: Distribucion de perfiles por area, porcentaje ponderado

Perfil	Urbano	Rural
Perfil 1	0.402	0.428
Perfil 2	0.257	0.119
Perfil 3	0.044	0.102
Perfil 4	0.158	0.111
Perfil 5	0.140	0.241




Figura 19: Distribucion del IVF por area urbana y rural.




Figura 20: Heterogeneidad SHAP entre area urbana y rural usando el modelo global sin geografia.

14. Robustez del indice

14.1. Bootstrap simple con resumen ponderado

La robustez se evaluo mediante bootstrap simple con $B = 200$. En cada iteracion se re-muestreo con reemplazo sin probabilidades proporcionales a FAC500A; luego se reestimo el GMM y se recalcularon R_k , IVF medio y distribucion de perfiles usando ponderaciones en los resmenes. Para resolver el posible intercambio de etiquetas entre perfiles, se alinearon los perfiles de cada iteracion con el modelo final segun correlacion de R_k .

Cuadro 29: Robustez bootstrap del IVF medio y de R_k por perfil, $B = 200$

Estadistico	Valor final	Media bootstrap	IC 95 %
IVF medio	0.4635	0.4636	[0.4635, 0.4637]
Perfil 1 (R_k)	0.5188	0.5040	[0.4748, 0.5542]
Perfil 2 (R_k)	0.3133	0.4013	[0.2416, 0.4437]
Perfil 3 (R_k)	0.5951	0.5895	[0.5402, 0.6051]
Perfil 4 (R_k)	0.4357	0.4460	[0.4164, 0.4665]
Perfil 5 (R_k)	0.5151	0.4736	[0.4464, 0.5053]




Figura 21: Bootstrap del IVF medio y de los R_k por perfil.

El IVF medio ponderado es altamente estable: el intervalo de confianza es prácticamente puntual y el coeficiente de variación bootstrap fue 0.0001. La variabilidad es mayor en los R_k por perfil, especialmente cuando el remuestreo altera la composición relativa de perfiles o cuando hay posible sensibilidad por tamaño de grupo.

15. Archivos exportados

El pipeline exporto bases, tablas y gráficos. Los CSV principales son `resultados_ivf.csv`, `bic_icl_comparacion.csv`, `estadisticas_perfiles.csv`, `bootstrap_robustez.csv`, `shap_comparacion_geo.csv` y `robustez_ivf_resumen.csv`. Los gráficos exportados son los reproducidos en este informe: `missing`, `MCA`, `Vi`, `seleccion de K`, `distribucion del IVF`, `heatmap socioeconomico`, `composicion territorial`, `matrices de confusion`, `resumenes SHAP`, `heterogeneidad urbano-rural` y `robustez bootstrap`.

16. Conclusiones

1. Se construyó un IVF continuo y probabilístico para personas no bancarizadas de 18 a 65 años, usando ENAH0 2024 y una matriz analítica que combina coordenadas MCA y variables continuas estandarizadas.
2. El GMM identificó cinco perfiles latentes. El Perfil 3 fue el más vulnerable y el Perfil 2 el menos vulnerable. El orden de vulnerabilidad fue Perfil 3, Perfil 1, Perfil 5, Perfil 4 y Perfil 2.
3. El IVF no se construye con una asignación dura de perfiles, sino con probabilidades posteriores. Esta decisión permite capturar casos intermedios y conservar la incertidumbre de clasificación.
4. La vulnerabilidad financiera estimada no depende solo del ingreso. Las variables laborales, educativas, digitales y de condiciones de vida son fundamentales para diferenciar perfiles.
5. La geografía no se usa directamente para formar perfiles ni calcular el IVF, pero sí ayuda a interpretar la distribución posterior de la vulnerabilidad, especialmente la mayor vulnerabilidad media en área rural.
6. XGBoost y SHAP son herramientas auxiliares de interpretación. No intervienen en la construcción del índice ni deben interpretarse como evidencia causal.
7. El bootstrap simple con 200 iteraciones muestra alta estabilidad del IVF medio ponderado, aunque los niveles R_k por perfil pueden variar más que el promedio agregado.

A. Salidas literales del notebook por bloque

Las siguientes salidas se incluyen para trazabilidad. Fueron extraídas del notebook actualizado sin re-ejecutar celdas. Los textos se muestran en formato monoespaciado y corresponden a las salidas de consola; los graficos ya fueron incorporados en las secciones principales.

Bloque 1: imports y configuracion global

Bloque 2: carga de modulos ENAHO

Bloque 3: integracion de modulos

Bloque 4: filtro de poblacion objetivo

Bloque 5: limpieza de centinelas y seleccion de variables

Bloque 6: diagnostico de valores faltantes e imputacion

Bloque 7: recodificacion geografica

Bloque 8: acceso digital y dificultad de pago

Bloque 9: recodificacion socioeconomica e ingreso

Bloque 10: separacion de variables

Bloque 11: MCA

Bloque 12: matriz final GMM**Bloque 13: score auxiliar Vi****Bloque 14: factor de expansion FAC500A****Bloque 15: seleccion de K****Bloque 16: ajuste final GMM****Bloque 16-BIS: perfilado de variables retiradas****Bloque 17: calculo de Rk****Bloque 18: construccion del IVF****Bloque 19: caracterizacion socioeconomica****Bloque 20: caracterizacion territorial****Bloque 21: XGBoost sin geografia****Bloque 22: XGBoost con geografia**

Bloque 23: comparacion SHAP sin/con geografia**Bloque 24: XGBoost Regressor sobre IVF****Bloque 24-BIS: SHAP desagregado por perfil****Bloque 25: heterogeneidad urbano-rural****Bloque 26: bootstrap simple de robustez****Bloque 27: exportacion de resultados**

B. Referencias

Referencias

- [1] Arian, H., Seyfi, S. M., & Sharifi, A. (2020). Forecasting probability of default for consumer loan management with Gaussian mixture models. *arXiv: General Economics*.
- [2] Biernacki, C., Celeux, G., & Govaert, G. (2000). Assessing a Mixture Model for Clustering with the Integrated Completed Likelihood. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 22(7), 719–725.
- [3] Busmann, N., Giudici, P., Marinelli, D., & Papenbrock, J. (2020). Explainable machine learning in credit risk management. *Computational Economics*, 57, 203–216.
- [4] Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*.
- [5] Fernandez-Lopez, S., & Alvarez-Espino, M. (2024). Financial vulnerability of households: multidimensional measurement and determinants. *Applied Economics / household finance literature*.
- [6] Kempson, E., McKay, S., & Willits, M. (2004). Characteristics of families in debt and the nature of indebtedness. *Department for Work and Pensions Research Report*.
- [7] Greenacre, M. (2007). *Correspondence Analysis in Practice* (2nd ed.). Chapman and Hall/CRC.
- [8] He, L., & Zhou, S. (2022). Household financial vulnerability to income and medical expenditure shocks: Measurement and determinants. *International Journal of Environmental Research and Public Health*, 19(8), 4480.
- [9] Hwang, Y., Lee, Y., & Fabozzi, F. J. (2022). Identifying household finance heterogeneity via deep clustering. *Annals of Operations Research*, 325, 1255–1289.
- [10] Instituto Nacional de Estadística e Informática. (2024). *Encuesta Nacional de Hogares sobre Condiciones de Vida y Pobreza: Microdatos ENAH0 2024*.
- [11] Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*.
- [12] McLachlan, G. J., & Peel, D. (2000). *Finite Mixture Models*. Wiley.
- [13] Nardo, M., Saisana, M., Saltelli, A., Tarantola, S., Hoffman, A. N., & Giovannini, E. (2005). *Handbook on Constructing Composite Indicators: Methodology and User Guide*. OECD.
- [14] Scrucca, L., Fop, M., Murphy, T. B., & Raftery, A. E. (2016). mclust 5: Clustering, classification and density estimation using Gaussian finite mixture models. *The R Journal*, 8(1), 289–317.
- [15] Shapley, L. S. (1988). A value for n-person games. En *Contributions to the Theory of Games*.